

Universidad Politécnica Salesiana

Sede Guayaquil

CARRERA: COMPUTACIÓN

ANTEPROYECTO

Previo a la obtención del título de Ingeniero en Ciencias de la Computación

TÍTULO

Desarrollo de un agente conversacional inteligente para la cotización de catálogos de materiales eléctricos en Guayaquil

AUTORES

Victor Jesus Totoy Iza

Rodolfo Damián Seminario Murillo

TUTOR

Ing. Joe Llerena Izquierdo, M.Sc., Ph.D.

Guayaquil, noviembre del 2026

Índice

1 Tema del Trabajo de Titulación 1

2 Antecedentes 1

3 Justificación 3

4 Objetivos 5
4.1 Objetivo General 5
4.2 Objetivos Específicos 5

5 Marco hipotético o preguntas de investigación 6
5.1 Preguntas de investigación 6
5.2 Hipótesis de investigación 6

6 Marco teórico referencial 7
6.1 Agentes conversacionales en la atención comercial 7
6.2 Modelos generativos de lenguaje extenso y arquitectura de agentes 7
6.3 Recuperación aumentada, bases de datos embebidas y estándares de ingeniería . 8

7 Metodología / Propuesta de desarrollo 9

8 Cronograma de actividades 13

9 Proyectos de investigación vinculados 14

10 Presupuesto del Proyecto de Titulación 15

11 Anexos 22
11.1 Anexo 1: Árbol de problemas y objetivos (Metodología 5W+H) 22
11.2 Anexo 2: Matriz de consistencia metodológica de la investigación 24
11.3 Anexo 3: Diagrama de arquitectura de software y flujo de procesamiento 26
11.4 Anexo 4: Repositorio de código abierto y transparencia de datos 27

Índice de figuras

1 Diagrama de flujo de las fases de la metodología de investigación 12
2 Árbol de problemas de la atención comercial en distribuidoras eléctricas 22
3 Árbol de objetivos de la solución de ingeniería de software 23
4 Arquitectura integral del agente conversacional con recuperación local de catálogos 26

Índice de tablas

1 Comparativa de trabajos previos en sistemas conversacionales para comercio técnico . . . 3
2 Estrategia de búsqueda y cadenas booleanas en bases de datos científicas 10
3 Cronograma de hitos del programa de titulación 13
4 Plan de actividades por fases del proyecto de titulación 14
5 Presupuesto detallado y valoración económica del proyecto de titulación 16
6 Análisis operativo de servicios de nube: Capa Gratuita vs. Régimen Comercial de Pago 17
7 Matriz de consistencia metodológica de la investigación (Formato Institucional UPS P69) 25

1. Tema del Trabajo de Titulación

Desarrollo de un agente conversacional inteligente para la cotización de catálogos de materiales eléctricos en Guayaquil

2. Antecedentes

Actualmente, el comercio conversacional a través de plataformas de mensajería instantánea constituye el canal preponderante de captación y venta técnica para las pequeñas y medianas empresas comerciales (Adam et al., 2021; Adamopoulou & Moussiades, 2020; Følstad & Brandtzæg, 2020; Luo et al., 2019). En el sector de la distribución de materiales eléctricos e ingeniería en la ciudad de Guayaquil, contratistas independientes, técnicos electricistas y empresas constructoras demandan cotizaciones inmediatas y continuas que involucran especificaciones rigurosas de marcas líderes como Schneider Electric, Siemens, Legrand, Centelsa y ABB. No obstante, este proceso se gestiona tradicionalmente de forma manual mediante asesores de mostrador que deben consultar dispersos catálogos en formato PDF y extensas hojas de cálculo de precios. Esta modalidad ocasiona tiempos de espera para el cliente que oscilan entre 2 y 8 horas hábiles, lo cual provoca una pérdida directa de oportunidades comerciales estimada entre el 20 % y el 35 % de las solicitudes recibidas, dado que los compradores migran rápidamente hacia competidores con mayor celeridad de respuesta. De no implementarse mecanismos tecnológicos que sistematicen la atención, las distribuidoras enfrentan un incremento sostenido de sus costos operativos y el deterioro gradual de la fidelización de sus clientes (Llerena-Izquierdo & Ayala-Carabajo, 2022; Llerena-Izquierdo & Ayala-Carabajo, 2025).

Diversas investigaciones previas abordaron la automatización del servicio al cliente mediante sistemas conversacionales computacionales. Adamopoulou y Moussiades (2020) documentaron la evolución histórica de los agentes conversacionales, demostrando que las arquitecturas iniciales basadas en árboles de decisión y expresiones regulares presentan una rigidez severa ante la variabilidad del lenguaje natural no contemplado en su diseño. Adam et al. (2021) y Sands et al. (2021) evidenciaron que la incorporación de señales de interacción antropomórfica y presencia social en asistentes virtuales incrementa la tasa de adopción y cumplimiento de los usuarios, mientras que Ashfaq et al. (2020) y Han (2023) modelaron los determinantes de satisfacción e intención de compra en entornos de comercio electrónico conversacional. Con la introducción de la arquitectura Transformer por Vaswani et al. (2017), los Modelos de Lenguaje Extenso (LLM) transformaron el procesamiento del lenguaje; consecuentemente, Wang et al. (2024) sistematizaron su aplicación en agentes autónomos capaces de inferir intenciones complejas y orquestar herramientas. Sin embargo, Ji et al. (2023) y Huang et al. (2024) demostraron que los modelos generativos producen alucinaciones probabilísticas al responder sobre datos no presentes en su entrenamiento, lo que resulta crítico en transacciones comerciales al alterar precios o inventarios. Para mitigar esta debilidad, Guu et al. (2020) y Lewis et al. (2020) formularon los fundamentos de la Generación Aumentada por Recuperación (RAG), mientras que

Borgeaud et al. (2022) y Gao et al. (2023) profundizaron en modelos de recuperación densa sobre corpus masivos. Asimismo, mientras que Wu et al. (2023) plantearon esquemas multiagente que requieren clústeres de servidores y múltiples llamadas secuenciales a los modelos, y Asai et al. (2024) propusieron marcos de auto-reflexión computacionalmente densos, Llerena-Izquierdo, Mendez-Reyes et al. (2024) y Llerena-Izquierdo, Fiallos-Vargas et al. (2024) validaron en el entorno local la factibilidad y eficacia de emplear modelos fundacionales modernos de alta velocidad (Gemini) en procesos aplicados.

A pesar de los aportes documentados, la literatura científica evidencia una brecha tecnológica sustancial en el despliegue de agentes inteligentes en entornos de recursos computacionales restringidos para empresas comerciales. Los sistemas RAG convencionales dependen de bases de datos vectoriales y modelos de incrustación de alta demanda de memoria RAM y GPU, lo que imposibilita su alojamiento en servidores de entrada en la nube de bajo costo (instancias con 1 GB de RAM). De igual forma, las arquitecturas multiagente incrementan la latencia a más de diez segundos por interacción, excediendo los límites estrictos de los webhooks de Meta y afectando la experiencia del usuario. No se ha evidenciado un modelo que resuelva la recuperación estructurada sobre catálogos técnicos multimarca donde la búsqueda precisa por atributos deterministas (código de fábrica, amperaje, calibre y marca) garantice cero alucinaciones de precios y conserve la memoria contextual de cada cliente en un único microservicio ligero.

Para resolver esta brecha, el presente proyecto técnico desarrollará un agente conversacional inteligente que integrará un modelo generativo multimodal con un mecanismo de recuperación local de catálogos eléctricos estructurados sobre una base de datos embebida SQLite con registro en modo Write-Ahead Logging (Gaffney et al., 2022). El agente operará como un servicio web asíncrono en .NET 8 conectado a la API oficial de WhatsApp Cloud y al modelo fundacional Gemini, tomando como escenario experimental a la distribuidora Power Electrimk de la ciudad de Guayaquil. Siguiendo la línea de investigación de Ayala-Carabajo y Llerena-Izquierdo (2026) sobre dominios cognitivos y sistemas inteligentes, la propuesta anclará deterministamente cada consulta a registros verificables de catálogo, garantizando precios exactos, latencia de respuesta sub-cuatro segundos y trazabilidad del cliente con costos de infraestructura mínimos. En la Tabla 1 se presenta el análisis comparativo del estado del arte.

Tabla 1
Comparativa de trabajos previos en sistemas conversacionales para comercio técnico

Autor	Técnica base	Ventajas identificadas	Limitaciones operativas
Adamopoulou y Moussiades (2020)	Árboles de decisión y patrones regex	Respuestas deterministas y predecibles	Rigidez ante variaciones de lenguaje natural
Adam et al. (2021)	Chatbot con señales antropomórficas	Alta aceptación y fluidez de usuario	Carece de verificación de datos técnicos y precios
Wang et al. (2024)	Agentes autónomos basados en LLM	Comprensión semántica flexible y herramientas	Alucinaciones factuales en cotizaciones exactas
Lewis et al. (2020); Gao et al. (2023)	RAG tradicional con base vectorial	Anclaje de respuestas a documentos extensos	Alto consumo de RAM/GPU y búsqueda inexacta
Wu et al. (2023)	Orquestación multiagente distribuida	Resolución colaborativa de tareas complejas	Alta latencia acumulada y costos prohibitivos

Nota. Elaboración propia a partir de la revisión sistemática de literatura sobre arquitecturas conversacionales.

3. Justificación

La presente investigación se justifica por la imperiosa necesidad de transformar el proceso operativo de cotización y asesoramiento técnico de materiales eléctricos en las distribuidoras comerciales que gestionan sus ventas a través de mensajería instantánea. En el mercado ecuatoriano de suministros eléctricos, la inmediatez y la certeza técnica determinan el cierre comercial; no obstante, el personal de ventas invierte una fracción considerable de su jornada laboral consultando hojas de cálculo, archivos PDF desactualizados y listas impresas para responder preguntas repetitivas sobre marcas, calibres, amperajes y precios. La incorporación de un asistente conversacional automatizado capaz de resolver estas solicitudes en tiempo real y con datos verificables confiere una ventaja competitiva directa y mitiga el riesgo de pérdida de clientes por demoras en la atención.

Desde una perspectiva técnica y científica, la integración de un modelo de lenguaje generativo con una capa de recuperación local estructurada resuelve de manera determinante el fenómeno de las alucinaciones probabilísticas y la inconsistencia fáctica en modelos fundacionales (Huang et al., 2024; Ji et al., 2023; Lewis et al., 2020; Tonmoy et al., 2024). En el campo de los suministros eléctricos, las alucinaciones no constituyen meros descuidos estilísticos; la invención de un calibre de conductor indebido, la alteración de la curva de disparo de un disyuntor termomagnético o la cita de un precio desactualizado acarrean riesgos severos de sobrecarga eléctrica, cortocircuito, siniestros materiales o pérdidas financieras. Si bien los modelos fundacionales como Gemini poseen una alta capacidad de comprensión sintáctica y semántica en lenguaje natural, carecen de acceso autónomo a inventarios específicos y dinámicos.

El empleo del motor relacional embebido SQLite con registro de escritura anticipada (WAL) permite realizar consultas deterministas de alta velocidad directamente en el espacio de memoria del proceso, inyectando los datos fácticos verificados (*ground truth*) dentro del contexto de inferencia. Esto erradica las discrepancias de catálogo y evita el despliegue de bases de datos vectoriales pesadas que demandan hardware costoso (Gaffney et al., 2022). Asimismo, la implementación del servicio en .NET 8 con patrones asíncronos bajo el paradigma de microservicios ligeros orientados a la nube garantiza la capacidad de atender múltiples sesiones simultáneas bajo consumo mínimo de memoria, en concordancia con los principios de desarrollo cloud-native y software asistido por inteligencia artificial promovidos en la disciplina (Kratzke & Quint, 2017; Llerena-Izquierdo, Fiallos-Vargas et al., 2024; Newman, 2021; Taibi et al., 2017).

En el ámbito social, productivo y de política pública, el proyecto se alinea de forma explícita con los objetivos del Plan Nacional de Desarrollo de la República del Ecuador, en sus ejes orientados a la transformación digital, la modernización de los encadenamientos productivos y el fortalecimiento de la competitividad de las micro, pequeñas y medianas empresas (MIPYMES). La distribuidora Power Electrimk, ubicada en la ciudad de Guayaquil, se beneficiará de una operatividad continua 24/7, canalizando prospectos calificados hacia sus ejecutivos de venta. Al mismo tiempo, los maestros eléctricos, contratistas y usuarios finales obtendrán especificaciones técnicas normalizadas y precios referenciales transparentes sin barreras geográficas ni demoras de atención.

En conformidad con los criterios de diseño en ingeniería (Criterio ABET 1), la solución se encuentra sujeta a cuatro restricciones formales de diseño:

1. **Restricción de latencia operativa:** El tiempo total de procesamiento y respuesta de extremo a extremo no deberá superar los 4.0 segundos por interacción, garantizando una experiencia fluida y evitando cancelaciones o reintentos en los webhooks de WhatsApp Cloud API.

2. **Restricción de hardware y costo de infraestructura:** El sistema deberá operar de manera estable en una instancia de entrada en la nube de bajos recursos (computación contenida a 1 vCPU y 1 GB de memoria RAM, equivalente a AWS EC2 t2.micro), manteniendo los costos operativos de infraestructura por debajo de 15.00 USD mensuales.

3. **Restricción de cumplimiento normativo y privacidad:** El manejo de identificadores de usuario, números telefónicos y registros de conversaciones deberá cumplir estrictamente con los mandatos de la Ley Orgánica de Protección de Datos Personales (LOPDP) de la República del Ecuador, empleando transporte seguro bajo TLS 1.3 y disociación de datos de contacto.

4. **Restricción de exactitud e integridad de catálogo:** Se impone una tolerancia de error nula (0 %), supeditando cualquier emisión de cotización a la coincidencia determinista con los registros oficiales de la base de datos local.

El alcance del proyecto comprende la recopilación y estructuración de los catálogos multimarca de la distribuidora, el diseño del esquema relacional local, el desarrollo del servicio backend en .NET 8 con integración a WhatsApp Cloud API y al modelo generativo Gemini, el despliegue productivo en una instancia Linux de AWS con proxy inverso Nginx y certificados TLS, y la evaluación experimental cuantitativa de latencia, precisión y consumo de recursos. Se delimita la solución a la emisión de cotizaciones referenciales, asesoramiento de compatibilidad y captura de requerimientos de prospectos. Quedan excluidos del alcance la recaudación de pagos directos mediante pasarelas financieras, la emisión de facturación electrónica reglamentada por el SRI y la conexión bidireccional con sistemas ERP legados.

4. Objetivos

4.1. Objetivo General

Desarrollar un agente conversacional inteligente para la cotización de catálogos de materiales eléctricos en Guayaquil, mediante la integración de WhatsApp Cloud API, el modelo generativo Gemini y una base de datos embebida SQLite con registro de escritura anticipada, orientado a la optimización operativa y comercial de la distribuidora Power Electrimk.

4.2. Objetivos Específicos

De conformidad con los niveles taxonómicos de Bloom orientados a proyectos de ingeniería computacional, se establecen los siguientes objetivos específicos:

- **Analizar** los requerimientos de atención técnica y comercial, la estructura de los catálogos multimarca de la distribuidora Power Electrimk y las técnicas de recuperación de información reportadas en la literatura científica reciente (2020–2026), mediante el levantamiento empírico de procesos y la revisión bibliográfica sistemática, para establecer las especificaciones funcionales y no funcionales del agente.
- **Implementar** un prototipo de software que integre un servicio backend en .NET 8, una capa de recuperación local determinista sobre SQLite con persistencia de sesiones conversacionales y la conexión asíncrona a WhatsApp Cloud API y al modelo generativo Gemini, desplegado en infraestructura de nube bajo protocolos de comunicación segura.
- **Evaluar** el desempeño computacional y la efectividad operativa del prototipo mediante pruebas experimentales comparativas que cuantifiquen la latencia de respuesta (milisegundos), la exactitud de precios y referencias técnicas (precisión porcentual) y el consumo de recursos de cómputo y memoria, contrastando el agente con recuperación local frente a esquemas no acoplados a inventario.

5. Marco hipotético o preguntas de investigación

En concordancia con la matriz metodológica institucional y los objetivos específicos planteados, se formulan las preguntas de sistematización del problema y las correspondientes hipótesis de ingeniería que guiarán la investigación experimental.

5.1. Preguntas de investigación

P1. ¿Cuáles son los requerimientos técnicos y funcionales, las estructuras de datos de catálogos multimarca y las estrategias de recuperación de información que permiten optimizar el asesoramiento comercial de materiales eléctricos en mensajería instantánea?
P2. ¿Cómo diseñar e implementar una arquitectura de software ligera en .NET 8 que integre de forma desacoplada la API de WhatsApp Cloud, el modelo generativo Gemini y un motor de base de datos embebido SQLite manteniendo la memoria conversacional de cada cliente?
P3. ¿En qué medida la incorporación de una capa de recuperación local estructurada sobre catálogos incide en la exactitud de precios y referencias técnicas, el tiempo de latencia y el consumo de recursos de computación (CPU y memoria RAM) en comparación con el uso del modelo generativo sin recuperación aumentada?

5.2. Hipótesis de investigación

Hipótesis General (HG). La implementación de un agente conversacional inteligente basado en el modelo generativo Gemini y una capa de recuperación local determinista sobre SQLite permite automatizar el proceso de cotización y asesoramiento de materiales eléctricos, alcanzando una exactitud de precios y referencias técnicas superior al 95 % y una latencia media de respuesta inferior a 4.0 segundos, con un perfil de consumo de recursos compatible con instancias de computación en la nube de bajos recursos.
Hipótesis Específica 1 (H1). La estructuración relacional del catálogo multimarca y la definición de un esquema de búsqueda indexado en SQLite facilitan la resolución de consultas de inventario técnico con tiempos de ejecución en base de datos inferiores a 100 milisegundos.
Hipótesis Específica 2 (H2). Una arquitectura asíncrona en .NET 8 con persistencia local de estado conversacional permite procesar los webhooks de WhatsApp Cloud API sin bloqueos de concurrencia y con utilización de memoria del proceso inferior a 250 megabytes.
Hipótesis Específica 3 (H3). El agente con recuperación local de catálogos presentará una tasa de alucinación en cotizaciones significativamente menor ($p < 0{,}05$) y una precisión de precios estadísticamente superior en comparación con el modelo generativo operando en modalidad directa sin recuperación contextual.

6. Marco teórico referencial

Esta sección fundamenta conceptualmente la formulación del artefacto de software propuesto, estructurando los conocimientos de manera deductiva desde los paradigmas de interacción hasta los mecanismos de persistencia y los estándares de ingeniería de software que rigen su implementación. Los contenidos se organizan en torno a tres constructos esenciales: los agentes conversacionales en la atención comercial, los modelos generativos de lenguaje extenso, y las técnicas de recuperación aumentada sobre motores embebidos.

6.1. Agentes conversacionales en la atención comercial

Un agente conversacional es un sistema de software diseñado para emular la interacción humana mediante procesamiento de lenguaje natural, facilitando la ejecución de tareas o la provisión de información de manera interactiva (Adamopoulou & Moussiades, 2020). Históricamente, las primeras arquitecturas comerciales se fundamentaron en árboles de decisión y cotejo de patrones basados en reglas sintácticas fijas; si bien estos sistemas exhiben un comportamiento estrictamente predecible, sufren de una fragilidad intrínseca ante variaciones semánticas, errores tipográficos o expresiones idiomáticas no contempladas por los analistas (Følstad & Brandtzæg, 2020). En el entorno del comercio electrónico conversacional, la percepción de naturalidad, comprensión contextual y empatía técnica condiciona directamente la satisfacción, la confianza del consumidor y su predisposición para culminar una transacción de compra (Adam et al., 2021; Ashfaq et al., 2020; Sands et al., 2021). Asimismo, estudios empíricos en mercadotecnia digital demuestran que la pericia percibida del asistente y la transparencia en su condición de agente artificial inciden significativamente en la intención de compra y en la fidelización del cliente técnico (Han, 2023; Luo et al., 2019). Cuando se trata de suministros técnicos como materiales eléctricos, el usuario no solo busca conocer un precio, sino que requiere una consulta orientativa sobre compatibilidad de voltaje, calibres conductores y disponibilidad de marcas sustitutas. Esta complejidad lingüística y semántica hace inviable el uso exclusivo de árboles estáticos y motiva la integración de modelos generativos avanzados en el núcleo de procesamiento del agente.

6.2. Modelos generativos de lenguaje extenso y arquitectura de agentes

Los modelos de lenguaje extenso (LLM) contemporáneos se basan en la arquitectura Transformer, cuyo mecanismo de autoatención captura dependencias globales de significado a lo largo de secuencias textuales complejas (Vaswani et al., 2017). Entrenados sobre volúmenes masivos de datos textuales, estos modelos exhiben capacidades emergentes para la inferencia contextual, el seguimiento riguroso de directrices delimitadas en mensajes de sistema (*system prompts*) y la adopción de roles comerciales especializados (Wang et al., 2024). No obstante, la naturaleza fundamentalmente probabilística de los LLM induce el fenómeno conocido como alucinación, en el cual el modelo produce aseveraciones sintácticamente coherentes pero fácticamente falsas o inexistentes en la realidad objetiva (Huang et al., 2024; Ji et al., 2023). Recientes

revisiones sistemáticas categorizan las alucinaciones en intrínsecas (contradicción directa de la fuente provista) y extrínsecas (invención de hechos no verificables), atribuyendo su origen a sesgos de preentrenamiento y fallas en la alineación paramétrica (Tonmoy et al., 2024). En un entorno industrial o comercial de distribución eléctrica, la invención de un precio unitario, una capacidad de interrupción inexistente o una certificación técnica errónea acarrea graves perjuicios comerciales y legales. Por consiguiente, resulta imperativo gobernar el comportamiento generativo mediante verificación de cadenas de conocimiento y mecanismos de anclaje determinista (*grounding*) (Dhuliawala et al., 2023), conocidos formalmente como generación aumentada por recuperación.

6.3. Recuperación aumentada, bases de datos embebidas y estándares de ingeniería

El paradigma de generación aumentada por recuperación (*Retrieval-Augmented Generation*, RAG) constituye una metodología híbrida que desacopla la memoria paramétrica del modelo de lenguaje de la fuente fáctica de verdad, consultando un almacén de datos estructurado o no estructurado antes de sintetizar la respuesta final (Borgeaud et al., 2022; Gao et al., 2023; Guu et al., 2020; Lewis et al., 2020). Si bien propuestas recientes exploran mecanismos avanzados de auto-reflexión y re-evaluación iterativa (*Self-RAG*) (Asai et al., 2024), tales enfoques imponen una penalización severa de latencia y costo computacional. En el contexto de catálogos de materiales eléctricos, donde las entidades poseen atributos inequívocos como código de parte, amperaje, marca y precio de lista, la recuperación basada en esquemas relacionales e índices lexicográficos presenta mayor precisión y predictibilidad que las representaciones vectoriales densas, evitando discrepancias de redondeo y falsos positivos semánticos.

Para satisfacer la restricción de hardware en entornos de bajo presupuesto computacional, el empleo de SQLite como motor embebido ofrece transacciones ACID completas dentro del mismo espacio de proceso de la aplicación, suprimiendo la sobrecarga de comunicación interproceso por sockets de red y el consumo de memoria asociado a servicios de bases de datos independientes (Gaffney et al., 2022). Al habilitar el modo de registro de escritura anticipada (*Write-Ahead Logging*, WAL), el motor soporta lecturas simultáneas altamente concurrentes sin bloquear las escrituras de actualización de catálogo o registro de sesiones. Asimismo, la estructuración del backend bajo principios de microservicios independientes y patrones *cloud-native* garantiza un despliegue desacoplado, mantenible y escalable con huella mínima de memoria en servidores virtuales de entrada (Kratzke & Quint, 2017; Newman, 2021; Taibi et al., 2017).

Asimismo, la construcción del artefacto se gobierna bajo el estándar internacional de calidad de producto software **ISO/IEC 25010:2011**, priorizando las características de adecuación funcional, eficiencia de desempeño (tiempo de respuesta y utilización de recursos), fiabilidad y seguridad (ISO/IEC, 2011). La seguridad de la información en el canal de mensajería se garantiza mediante el protocolo **TLS 1.3** (RFC 8446) para el cifrado en tránsito (Rescorla, 2018), complementado con la verificación de firmas criptográficas HMAC-SHA256 exigida por WhatsApp Cloud API para autenticar la legitimidad de cada webhook entrante. Estos fundamentos teóricos,

metodológicos y normativos proporcionan el marco de referencia indispensable sobre el cual se articula la propuesta de desarrollo técnico descrita en la siguiente sección.

7. Metodología / Propuesta de desarrollo

La presente investigación adopta un alcance descriptivo y aplicado, bajo un enfoque metodológico mixto predominantemente cuantitativo y con un diseño cuasi-experimental de corte transversal. Según su propósito, constituye una investigación tecnológica orientada a la concepción, ingeniería y validación empírica de un artefacto de software; según el método de inferencia, es de naturaleza deductiva al derivar hipótesis operativas a partir de constructos teóricos consolidados; según la procedencia de la información, combina fuentes secundarias documentales (catálogos de fabricantes, especificaciones técnicas y literatura científica indexada) con datos primarios generados durante las pruebas automatizadas del sistema. La recolección de datos se sustentará en el registro automatizado de trazas de telemetría y métricas de rendimiento en servidor, complementado con entrevistas semiestructuradas al equipo comercial para el levantamiento de requerimientos de dominio (Llerena-Izquierdo & Ayala-Carabajo, 2022).

El desarrollo del proyecto se estructurará rigurosamente en cinco fases consecutivas e iterativas:

En la **Fase 1: Revisión bibliográfica y análisis de requerimientos**, se llevará a cabo una revisión sistemática de literatura fundamentada en las directrices metodológicas para ingeniería de software de Kitchenham y Charters (2007) y el estándar de reporte **PRISMA 2020** (Llerena-Izquierdo & Ayala-Carabajo, 2025; Page et al., 2021). El protocolo de búsqueda se estructurará a partir de cuatro constructos esenciales: (1) agentes conversacionales y modelos de lenguaje extenso, (2) arquitecturas de recuperación aumentada (*Retrieval-Augmented Generation*, RAG), (3) comercio conversacional y ventas técnicas sobre catálogos estructurados, y (4) mitigación de alucinaciones y eficiencia computacional en microservicios ligeros. En la Tabla 2 se detallan las ecuaciones y cadenas booleanas de búsqueda formuladas y ejecutadas en las principales bases de datos científicas indexadas (Scopus, Web of Science, IEEE Xplore, ScienceDirect y ACM Digital Library). Los criterios de inclusión consideraron artículos de revistas y conferencias revisados por pares publicados entre 2020 y 2026 en inglés o español; se excluyeron artículos sin acceso a texto completo o con enfoques puramente teóricos no replicables en software. De forma paralela, se levantarán los requerimientos funcionales y técnicos con el personal de la distribuidora Power Electrimk, inventariando las marcas distribuidas (e.g., Bticino, Schneider Electric, Phelps Dodge, Centelsa, Legrand, Siemens, ABB, Veto) y digitalizando los catálogos técnicos y listas de precios para estandarizar los atributos esenciales de los productos.

Tabla 2
Estrategia de búsqueda y cadenas booleanas en bases de datos científicas

Base de datos	Cadena de búsqueda booleana formal	Filtros y alcance
Scopus (Elsevier)	`TITLE-ABS-KEY(("conversational agent*" OR "chatbot*" OR "LLM") AND ("retrieval-augmented generation" OR "RAG" OR "grounding") AND ("e-commerce" OR "catalog*" OR "sales" OR "customer service") AND ("hallucination*" OR "latency"))`	Título, resumen y palabras clave; período 2020–2026; artículos de revista y actas de congreso.
Web of Science (Clarivate)	`TS=(("conversational agent*" OR "chatbot*" OR "conversational AI") AND ("retrieval-augmented generation" OR "RAG") AND ("commerce" OR "sales" OR "catalog" OR "customer support"))`	Topic (TS: título, resumen, keywords); índices SCI-Expanded y ESCI; 2020–2026.
IEEE Xplore	`(("conversational agent" OR "chatbot") AND ("retrieval-augmented generation" OR "RAG") AND ("e-commerce" OR "customer service"))`	Document Title, Abstract, Index Terms; conferencias y revistas IEEE; 2020–2026.
ScienceDirect (Elsevier)	`("conversational agent" OR "chatbot") AND ("retrieval-augmented generation" OR "RAG") AND ("customer service" OR "e-commerce")`	Title, abstract, keywords; área Computer Science; artículos revisados por pares.
ACM Digital Library	`+("conversational agent" "chatbot") +("retrieval-augmented generation" "RAG") +("e-commerce" "sales")`	The ACM Guide to Computing Literature; publicaciones arbitradas 2020–2026.

Nota. Ecuaciones de búsqueda diseñadas bajo el protocolo de Kitchenham y Charters (2007) y las directrices PRISMA 2020 (Page et al., 2021) para garantizar la exhaustividad, pertinencia y reproducibilidad de la revisión sistemática.

En la **Fase 2: Diseño de la arquitectura propuesta**, se definirá la arquitectura de software en capas basada en microservicios ligeros, estableciendo el esquema relacional en SQLite con optimización de índices para búsqueda textual rápida y soporte de transacciones concurrentes bajo modo WAL. Se diseñará el flujo de control para la verificación y consumo de los webhooks de WhatsApp Cloud API, la lógica de recuperación de productos afines a partir del mensaje del cliente y el mensaje de sistema (*system prompt*) que gobernará el comportamiento del modelo generativo Gemini (Zerega-Prado & Llerena-Izquierdo, 2022).

En la **Fase 3: Desarrollo del prototipo funcional**, se programará el servicio web en lenguaje C# sobre la plataforma .NET 8, aprovechando sus características nativas de alto rendimiento asíncrono y bajo consumo de memoria. Se implementará el módulo de persistencia y contexto conversacional por número de teléfono, el conector HTTP con autenticación Bearer hacia la API de WhatsApp, la capa de consulta de inventario determinista y la integración con

el SDK de Google Gemini para la síntesis de respuestas comerciales fluidas (Llerena-Izquierdo, Mendez-Reyes et al., 2024).

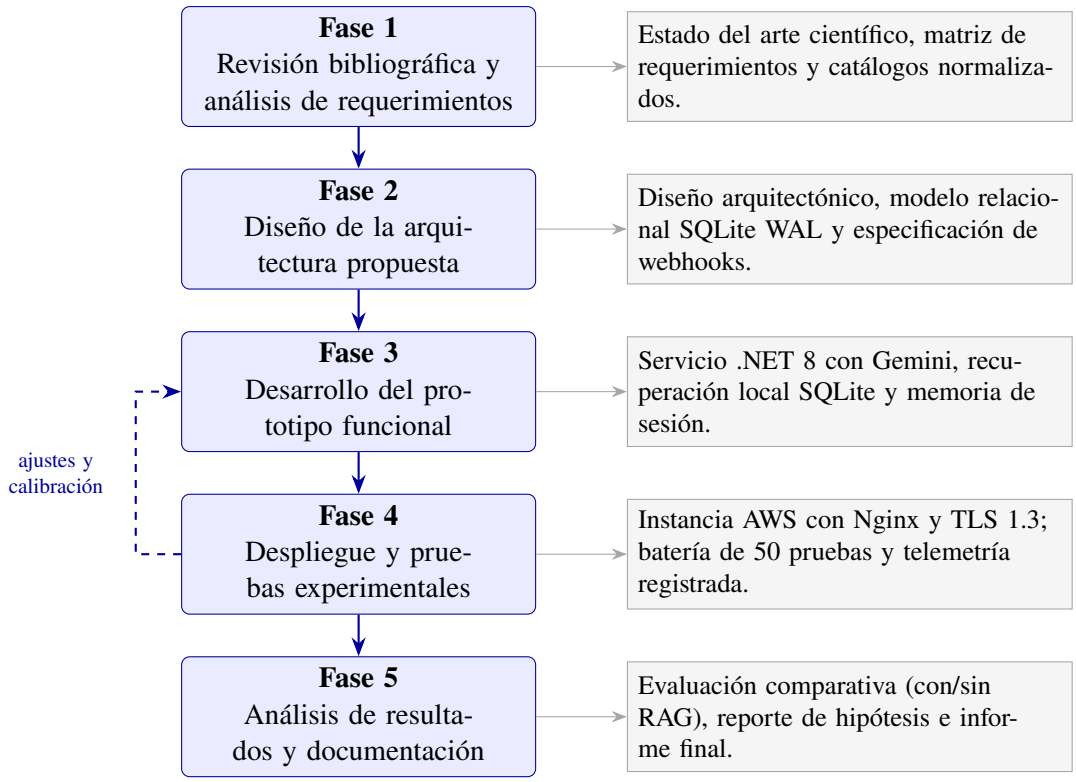
En la **Fase 4: Despliegue y pruebas experimentales**, el prototipo se desplegará en una instancia virtual Linux (Ubuntu 24.04.5 LTS) en Amazon Web Services (AWS EC2 t2.micro, acogida a la Capa Gratuita de 750 horas mensuales), configurando un servidor Nginx como proxy inverso hacia el runtime Kestrel en puerto 5252, administrado por el demonio Systemd (`agenteventas.service`) y con terminación de certificados de seguridad TLS 1.3 emitidos por Certbot (Let's Encrypt) bajo el subdominio oficial `agente.powerelectrimk.com`. Se ejecutará un protocolo experimental automatizado compuesto por una batería de $N = 50$ casos de prueba estructurados (búsquedas por código exacto, por especificación técnica, por categoría y solicitudes multimarca), comparando el desempeño del agente con recuperación local determinista frente al modelo generativo sin recuperación para cuantificar la tasa de eliminación de alucinaciones en precios y referencias de catálogo.

En la **Fase 5: Análisis de resultados y documentación**, se procesarán estadísticamente las métricas de latencia de respuesta, porcentaje de exactitud en precios y referencias técnicas, tasa de alucinación y utilización de memoria RAM y procesador en el servidor. Los resultados se contrastarán contra las hipótesis de investigación planteadas, y se redactará el informe técnico final de titulación de conformidad con las directrices institucionales (Llerena-Izquierdo et al., 2026).

La Figura 1 sintetiza el flujo de fases del proyecto y los entregables correspondientes a cada etapa de la investigación.

Figura 1

Diagrama de flujo de las fases de la metodología de investigación



Nota. El diagrama ilustra la progresión secuencial de las cinco fases metodológicas y sus entregables tangibles, incluyendo el lazo de retroalimentación de ajustes entre la fase experimental y el código del prototipo.

Para la evaluación formal del sistema se han operacionalizado las siguientes métricas experimentales:

- **Latencia de respuesta ($T_{\mathbf{resp}}$):** Tiempo total transcurrido en segundos desde la recepción del evento HTTP en el webhook hasta la emisión de la llamada de respuesta a la API de WhatsApp, medido con precisión de milisegundos mediante marcas de tiempo en el servidor.
- **Exactitud de cotización ($Acc_{\mathbf{cot}}$):** Porcentaje de cotizaciones emitidas donde los códigos de producto, marcas y precios unitarios coinciden exactamente con los registros vigentes del inventario oficial, definido como:

$$Acc_{\text{cot}} = \left(\frac{C_{\text{correctas}}}{C_{\text{totales}}} \right) \times 100\,\% \tag{1}$$

- **Tasa de alucinación ($H_{\mathbf{rate}}$):** Proporción de respuestas en las que el modelo generativo asevera precios inexistentes, inventa atributos de productos o recomienda ítems no catalogados en la base de datos comercial.
- **Consumo de recursos:** Perfil de utilización de memoria RAM del proceso .NET (en megabytes) y porcentaje promedio de ocupación de CPU en la instancia de nube durante

ráfagas de consultas.

8. Cronograma de actividades

El desarrollo del proyecto de titulación se estructurará a lo largo de un período académico regular, ajustándose de forma estricta a los hitos de evaluación y seguimiento dispuestos por la Comisión de Titulación de la carrera, tal como se detalla en la Tabla 3.

Tabla 3

Cronograma de hitos del programa de titulación

Hito institucional	**Entregable / Alcance**	**Fecha límite**
Presentación y aprobación	Aprobación oficial del tema de titulación	30/11/2026
Hito 1 (25 %)	Estado del arte, requerimientos y catálogos	21/12/2026
Hito 2 (50 %)	Diseño arquitectónico y esquema de datos	25/01/2027
Hito 3 (75 %)	Prototipo funcional desplegado en la nube	01/03/2027
Hito 4 (100 %)	Evaluación experimental e informe final	05/04/2027

Nota. Cronograma oficial de hitos académicos y ponderaciones de avance de acuerdo con la planificación de la Universidad Politécnica Salesiana.

Para garantizar la culminación exitosa de los objetivos planteados dentro del límite normativo de 400 horas de dedicación estudiantil, se presenta en la Tabla 4 el desglose pormenorizado de actividades por cada una de las cinco fases de la investigación, indicando su carga horaria estimada, fechas de inicio y culminación, y los responsables asignados.

Tabla 4

Plan de actividades por fases del proyecto de titulación

Actividad	Horas	Inicio	Fin	Responsables
Fase 1: Revisión bibliográfica y análisis de requerimientos				
Revisión sistemática de literatura científica	40	01/12/2026	12/12/2026	Autores
Levantamiento de requerimientos y digitalización	30	14/12/2026	21/12/2026	Autores / Tutor
Fase 2: Diseño de la arquitectura propuesta				
Diseño arquitectónico y modelado relacional SQLite	40	22/12/2026	11/01/2027	Autores
Estructuración de índices y normalización multimarca	30	12/01/2027	25/01/2027	Autores
Fase 3: Desarrollo del prototipo funcional				
Implementación del backend .NET 8 y memoria de sesión	60	26/01/2027	12/02/2027	Autores
Integración con API Gemini y WhatsApp Cloud API	40	15/02/2027	01/03/2027	Autores
Fase 4: Despliegue y pruebas experimentales				
Despliegue en AWS con Nginx TLS y batería de pruebas	60	02/03/2027	19/03/2027	Autores
Fase 5: Análisis de resultados y documentación				
Análisis estadístico de telemetría y redacción del informe	60	20/03/2027	05/04/2027	Autores / Tutor
Subtotal de horas planificadas	360			
Horas de contingencia y ajustes (10 %)	40			
Total planificado	**400**			

Nota. Distribución del esfuerzo de ingeniería en 360 horas de ejecución técnica y 40 horas de contingencia para imprevistos o ajustes experimentales, completando las 400 horas reglamentarias.

La articulación entre el plan de actividades (Tabla 4) y los hitos institucionales (Tabla 3) asegura un avance disciplinado y continuo, permitiendo la verificación temprana de los componentes de software antes de la fase de evaluación experimental definitiva.

9. Proyectos de investigación vinculados

El presente trabajo de titulación, desarrollado por los estudiantes **Victor Jesus Totoy Iza** y **Rodolfo Damián Seminario Murillo**, se ejecuta bajo la dirección y tutoría del docente investigador Ing. Joe Llerena Izquierdo, M.Sc., Ph.D., y se encuentra formalmente articulado a las actividades científicas del **Grupo de Investigación en Enseñanza-Aprendizaje de las Ciencias para la Ingeniería (GIEACI)** de la Universidad Politécnica Salesiana, Sede Guayaquil.

Específicamente, los postulantes solicitan su adhesión formal al proyecto de investigación institucional titulado:

el cual se inscribe en la línea de investigación institucional de la carrera de Computación denominada: *«Integración de Tecnologías Emergentes en la Educación en Ingeniería y Sistemas Inteligentes»*.

La vinculación con dicho proyecto de investigación se fundamenta en que el desarrollo del agente conversacional no solo aborda la dimensión técnica del software y la ingeniería de datos sobre SQLite, sino que aporta evidencia empírica directa sobre los dilemas de confiabilidad, sesgo y ética algorítmica derivados del uso de modelos generativos fundacionales en entornos de interacción humana real (Ayala-Carabajo & Llerena-Izquierdo, 2026; Llerena-Izquierdo, Mendez-Reyes et al., 2024). Los hallazgos sobre alucinaciones de precios, gobernanza de datos personales bajo la LOPDP ecuatoriana y patrones de interacción en mensajería instantánea enriquecerán las publicaciones y análisis del grupo GIEACI respecto a la adopción responsable de la inteligencia artificial.

10. Presupuesto del Proyecto de Titulación

El presupuesto estimado para la ejecución integral del proyecto de titulación considera tanto la valoración formal del esfuerzo de ingeniería de software (mano de obra de los tesistas), como el dimensionamiento técnico de la infraestructura computacional en la nube, conectividad, licencias de consumo y suministros requeridos para el ciclo de vida del software. En la Tabla 5 se expone la valoración económica formal del proyecto, cuantificada conforme a precios de mercado y aranceles profesionales de desarrollo.

Tabla 5

Presupuesto detallado y valoración económica del proyecto de titulación

Categoría / Rubro	Descripción y dedicación del recurso	Costo (USD)
1. Mano de obra de ingeniería y desarrollo (Tesistas)		
Victor Jesús Totoy Iza	Arquitectura backend (.NET 8), webhooks y despliegue (200 h a $10.00/h)	2000.00
Rodolfo Damián Seminario Murillo	Esquema relacional SQLite, orquestación Gemini y pruebas (200 h a $10.00/h)	2000.00
Subtotal Mano de obra de ingeniería		*4000.00*
2. Infraestructura tecnológica, servicios y suministros directos		
Servidor en la nube (AWS EC2)	Instancia virtual Linux (t2.micro) durante 6 meses de proyecto	60.00
Nombre de dominio y gestión TLS	Dominio `powerelectrimk.com` y gestión de DNS Cloudflare (1 año)	15.00
Consumo de inferencia API Gemini	Cuota de tokens para pruebas de integración y validación ($N = 50$)	40.00
Línea telefónica comercial	Tarjeta SIM y recargas para WhatsApp Business API	25.00
Servicio de acceso a Internet	Conectividad fija de banda ancha durante 6 meses ($30.00/mes)	180.00
Impresión y encuadernación	Empastado y documentación física institucional de titulación	70.00
Fondo de contingencia	Margen para imprevistos operativos y pruebas adicionales (10 %)	40.00
Subtotal Infraestructura y suministros		*430.00*
Total general valorado del proyecto		**4430.00**

Nota. Valores expresados en dólares de los Estados Unidos de América (USD). La tarifa horaria de 10.00 USD/h se fundamenta en los valores referenciales de mercado para desarrolladores de software junior en Ecuador. Los costos directos de infraestructura y servicios (430.00 USD) y la mano de obra de investigación (4000.00 USD) son asumidos íntegramente por los autores.

Como se expone en la Tabla 5, el costo consolidado del proyecto asciende a 4430.00 USD. De este valor, el 90.3 % (4000.00 USD) corresponde a la mano de obra de ingeniería aportada por los tesistas (Victor Jesús Totoy Iza y Rodolfo Damián Seminario Murillo), cuantificada en 400 horas de dedicación conjunta (200 horas individuales) a una tarifa estandarizada de 10.00 USD por hora, representando la inversión de capital humano inherente a la formación en ingeniería en computación.

Por otra parte, desde la perspectiva operativa y financiera de la puesta en marcha, el proyecto exhibe una ventaja competitiva excepcional gracias al aprovechamiento estratégico de las **capas gratuitas** (*Free Tiers*) ofrecidas por los principales proveedores tecnológicos de nube e inteligencia artificial. Durante la etapa de investigación, desarrollo y validación experimental,

los costos computacionales de la nube y de la API de inferencia se reducen de forma efectiva a 0.00 USD. En la Tabla 6 se presenta el análisis comparativo entre los límites operativos de la Capa Gratuita y la estructura tarifaria de pago (*Pay-as-you-go*) para cuando la empresa distribuidora Power Electrimk decida escalar la solución a régimen comercial masivo.

Tabla 6

Análisis operativo de servicios de nube: Capa Gratuita vs. Régimen Comercial de Pago

Proveedor / Servicio	**Capa Gratuita (Free Tier)**	**Régimen Comercial (Pay-as-you-go)**	**Gasto Fase Tesis**
Google Gemini API (Google AI Studio)	15 RPM, 1 000 000 TPM y hasta 1 500 solicitudes/día gratuitas (*Flash*).	Entrada: \$0.075 / 1M tokens. Salida: \$0.30 / 1M tokens (≈ \$2.50/mes por 1 000 chats/día).	0.00
Amazon Web Services (AWS EC2 t2.micro)	750 horas/mes gratuitas durante 12 meses; 30 GB almacenamiento SSD EBS gp3.	On-Demand: \$0.0116/h (≈ \$8.35/mes) + \$2.40/mes almacenamiento EBS gp3.	0.00
Meta Cloud API (WhatsApp Business)	1 000 conversaciones de servicio al cliente al mes gratuitas iniciadas por usuario.	Tarifa variable por categoría de conversación (≈ \$0.008 a \$0.035 USD/chat tras superar 1 000).	0.00
Let's Encrypt / Certbot (Certificado TLS 1.3)	Certificados criptográficos SSL/TLS automatizados de renovación continua (100 % gratis).	Certificados comerciales corporativos con validación de organización (\$15.00 a \$60.00/año).	0.00
Dominio y DNS (Cloudflare / Namecheap)	DNS seguro gratuito en Cloudflare; registro de dominio de pago.	Renovación anual de dominio comercial powerelectrimk.com a precio de mercado.	15.00
Conectividad fija (Proveedor local)	No aplica capa gratuita comercial.	Tarifa residencial/comercial mensual de banda ancha simétrica (\$30.00/mes × 6 meses).	180.00
Desembolso directo real de infraestructura en fase de investigación			**195.00**

Nota. Datos oficiales recopilados de la documentación técnica y tablas de facturación de Google Cloud / Google AI Studio (2026), Amazon Web Services Free Tier y Meta for Developers. El gasto real de 195.00 USD demuestra la alta viabilidad financiera del proyecto para su validación en la distribuidora Power Electrimk.

Este análisis evidencia que la combinación de un motor embebido SQLite (modo WAL sin costo de licenciamiento) con la Capa Gratuita de Google AI Studio y el AWS Free Tier minimiza el riesgo de inversión para la distribuidora Power Electrimk, requiriendo un desembolso directo de únicamente 195.00 USD durante los seis meses de ejecución del proyecto de titulación. Si la distribuidora decidiera extender la solución a un volumen comercial de alta demanda superando los límites de la capa gratuita, el esquema de cobro por consumo de Gemini Flash garantiza

que el costo mensual de inferencia por cada 1 000 cotizaciones atendidas no excederá los 3.00 USD, lo cual consolida la sostenibilidad económica y el retorno de inversión del sistema frente a plataformas propietarias de alto costo recurrente.

Referencias Bibliográficas

Adam, M., Wessel, M., & Benlian, A. (2021). AI-based chatbots in customer service and their effects on user compliance. *Electronic Markets*, *31*(2), 427-445. https://doi.org/10.1007/s12525-020-00414-7

Adamopoulou, E., & Moussiades, L. (2020). Chatbots: History, technology, and applications. *Machine Learning with Applications*, *2*, 100006. https://doi.org/10.1016/j.mlwa.2020.100006

Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2024). Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. *The Twelfth International Conference on Learning Representations (ICLR 2024)*. https://openreview.net/forum?id=hSyW5go0v8

Ashfaq, M., Yun, J., Yu, S., & Loureiro, S. M. C. (2020). I, Chatbot: Modeling the factors to accept conversational agents for customer service. *Telematics and Informatics*, *54*, 101473. https://doi.org/10.1016/j.tele.2020.101473

Ayala-Carabajo, R., & Llerena-Izquierdo, J. (2026). Comparative Experimental Studies on Superior Cognitive Domains: AI Versus Humans. *Technologies*, *14*(1), 55. https://doi.org/10.3390/technologies14010055

Borgeaud, S., Mensch, A., Hoffmann, J., Cai, T., Rutherford, E., Millican, K., van den Driessche, G., Lespiau, J.-B., Damoc, B., Clark, A., de Las Casas, D., Guy, A., Menick, J., Ring, R., Hennigan, T., Huang, S., Maggiore, L., Jones, C., Cassirer, A., . . . Sifre, L. (2022). Improving Language Models by Retrieving from Trillions of Tokens. *Proceedings of the 39th International Conference on Machine Learning (ICML 2022)*, *162*, 2206-2240. https://doi.org/10.48550/arXiv.2112.04426

Dhuliawala, S., Komeili, M., Xu, J., Raileanu, R., Li, X., Celikyilmaz, A., & Weston, J. (2023). Chain-of-Verification Reduces Hallucination in Large Language Models. https://doi.org/10.48550/arXiv.2309.11495

Følstad, A., & Brandtzæg, P. B. (2020). Users' experiences with chatbots: findings from a large-scale survey. *Quality and User Experience*, *5*(1), 1-16. https://doi.org/10.1007/s41239-020-00024-7

Gaffney, K. P., Prammer, M., Brasfield, L., Hipp, D. R., Kennedy, D., & Patel, J. M. (2022). SQLite: Past, Present, and Future. *Proceedings of the VLDB Endowment*, *15*(12), 3535-3547. https://doi.org/10.14778/3554821.3554842

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2023). Retrieval-Augmented Generation for Large Language Models: A Survey. https://doi.org/10.48550/arXiv.2312.10997

Guu, K., Lee, K., Tung, Z., Pasupat, P., & Chang, M.-W. (2020). REALM: Retrieval-Augmented Language Model Pre-Training. *Proceedings of the 37th International Conference on Machine Learning (ICML 2020)*, *119*, 3929-3938.

Han, M. C. (2023). The effect of AI chatbot's perceived expertise on purchase intention in e-commerce. *Journal of Retailing and Consumer Services*, *75*, 103520. https://doi.org/10.1016/j.jretconser.2023.103520

Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2024). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. *ACM Computing Surveys*, *56*(12), 1-37. https://doi.org/10.1145/3703159

ISO/IEC. (2011). ISO/IEC 25010:2011: Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — System and software quality models. https://www.iso.org/standard/35733.html

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, *55*(12), 1-38. https://doi.org/10.1145/3571730

Kitchenham, B., & Charters, S. (2007). *Guidelines for performing Systematic Literature Reviews in Software Engineering* (inf. téc. N.º EBSE 2007-001). Keele University y University of Durham.

Kratzke, N., & Quint, P.-C. (2017). Understanding Cloud-Native Applications after 10 Years of Cloud Computing: A Systematic Mapping Study. *Journal of Systems and Software*, *126*, 1-16. https://doi.org/10.1016/j.jss.2017.01.001

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*, *33*, 9459-9474.

Llerena-Izquierdo, J., & Ayala-Carabajo, R. (2022). Desarrollo de competencia investigativa de estudiantes universitarios de ingeniería en proceso de titulación: propuesta metodológica y experiencia. *Memoria Investigaciones en Ingeniería*, (23), 50-62. https://doi.org/10.36561/ING.23.5

Llerena-Izquierdo, J., & Ayala-Carabajo, R. (2025). *Guía práctica para redactar y publicar manuscritos científicos*. Ediciones Abya-Yala. https://doi.org/10.17163/abyaups.134

Llerena-Izquierdo, J., Fiallos-Vargas, I., Portugal-Gorozabel, J., & Veloz-Arce, A. (2024). Towards an experience in AI-driven development for programming applied to multimedia using Tabnine. *2024 IEEE URUCON*, 1-5. https://doi.org/10.1109/URUCON63440.2024.10850207

Llerena-Izquierdo, J., Lindao-Cacao, K., Espinoza-Rosero, G., & Carrera-Jimenez, J. (2026). Towards a Management Model for the Final Year Project in Computer Engineering in the Field of Research. En M. V. Garcia, J.-P. Reyes, C. Nuñez & C. Gordón-Gallegos (Eds.), *Proceedings of the International Conference on Computer Science, Electronics and Industrial Engineering (CSEI 2024)* (pp. 37-49). Springer Nature Switzerland. https://doi.org/10.1007/978-3-031-98890-5_3

Llerena-Izquierdo, J., Mendez-Reyes, J., Ayala-Carabajo, R., & Andrade-Martinez, C. (2024). Innovations in Introductory Programming Education: The Role of AI with Google Colab and Gemini. *Education Sciences*, *14*(12), 1330. https://doi.org/10.3390/educsci14121330

Luo, X., Tong, S., Fang, Z., & Qu, Z. (2019). Frontiers: Machines vs. Humans: The Impact of Artificial Intelligence Chatbot Disclosure on Customer Purchases. *Marketing Science*, *38*(6), 937-947. https://doi.org/10.1287/mksc.2019.1192

Newman, S. (2021). *Building Microservices: Designing Fine-Grained Systems* (2.ª ed.). O'Reilly Media.

Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., . . . Moher, D. (2021). The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, *372*, n71. https://doi.org/10.1136/bmj.n71

Rescorla, E. (2018). *The Transport Layer Security (TLS) Protocol Version 1.3* (RFC N.º 8446). Internet Engineering Task Force. https://doi.org/10.17487/RFC8446

Sands, S., Ferraro, C., Campbell, C., & Tsao, H.-Y. (2021). Managing the human-chatbot frontier: How social presence impacts customer satisfaction. *European Journal of Marketing*, *55*(9), 2329-2347. https://doi.org/10.1108/EJM-01-2020-0052

Taibi, D., Lenarduzzi, V., & Pahl, C. (2017). Processes, Motivations, and Issues for Migrating to Microservices: An Empirical Study. *IEEE Cloud Computing*, *4*(5), 22-32. https://doi.org/10.1109/MCC.2017.4250931

Tonmoy, S. M. T. I., Zaman, S. M. M., Jain, V., Rani, A., Rawte, V., Chadha, A., & Das, A. (2024). A Comprehensive Survey of Hallucination in Large Language Models. https://doi.org/10.48550/arXiv.2402.04055

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, *30*, 5998-6008.

Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., & Wen, J. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, *18*(6), 186345. https://doi.org/10.1007/s11704-024-40231-1

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., & Wang, C. (2023). AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. https://doi.org/10.48550/arXiv.2308.08155

Zerega-Prado, J., & Llerena-Izquierdo, J. (2022). Arquitectura de consolidación de la información para seguros de la salud mediante Big Data. *Memoria Investigaciones en Ingeniería*, (23), 18-31. https://doi.org/10.36561/ING.23.3

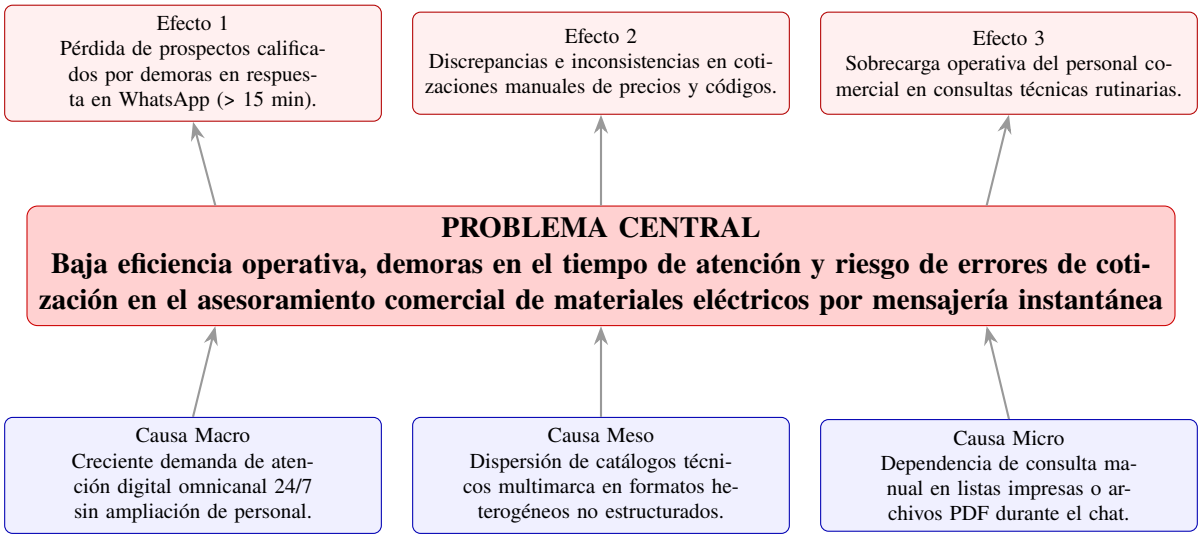
11. Anexos

11.1. Anexo 1: Árbol de problemas y objetivos (Metodología 5W+H)

De acuerdo con la guía metodológica de formulación de proyectos 5W+H de la Universidad Politécnica Salesiana, se presentan en la Figura 2 y la Figura 3 las representaciones causales del problema central y su transformación propositiva hacia los medios y fines de la solución técnica.

Figura 2

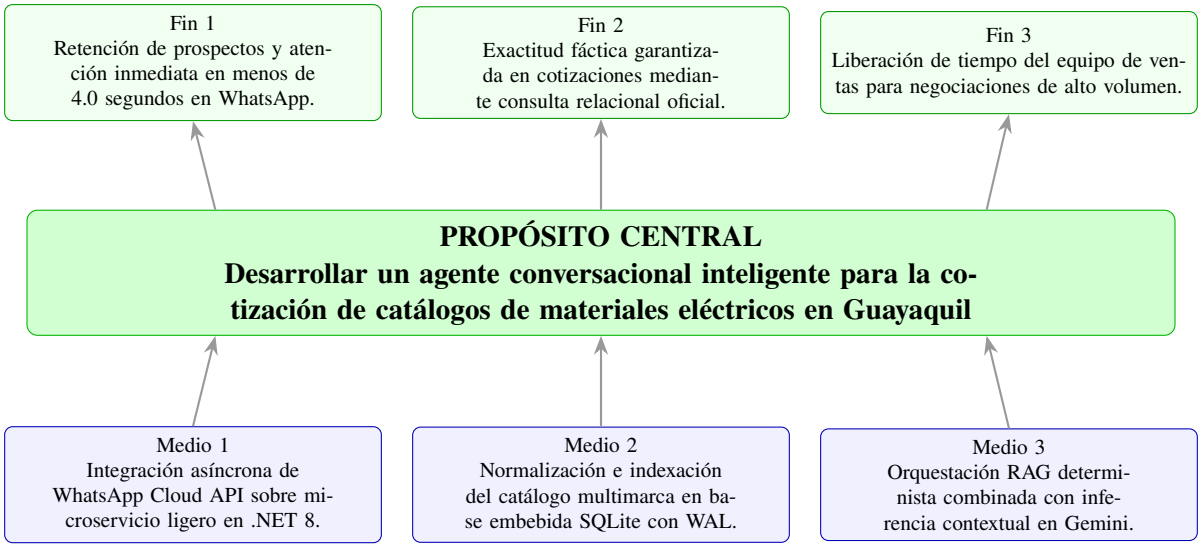
Árbol de problemas de la atención comercial en distribuidoras eléctricas



Nota. Estructura causal del problema identificada a través de la metodología 5W+H en la distribuidora Power Electrimk.

Figura 3

Árbol de objetivos de la solución de ingeniería de software



Nota. Transformación de medios y fines orientada a la ingeniería de software y la validación experimental.

11.2. Anexo 2: Matriz de consistencia metodológica de la investigación

En la Tabla 7 se detalla la Matriz de Consistencia Metodológica elaborada bajo el formato normativo institucional UPS P69, evidenciando la coherencia entre problemas, objetivos, hipótesis, variables e indicadores.

Tabla 7

Matriz de consistencia metodológica de la investigación (Formato Institucional UPS P69)

Problema	Objetivos	Hipótesis	Variables	Indicadores	Técnicas e Instrumentos
Problema General (PG): ¿Cómo mejorar la eficiencia, inmediatez y exactitud en la cotización y asesoramiento de materiales eléctricos en una distribuidora mediante mensajería instantánea?	**Objetivo General (OG):** Desarrollar un agente conversacional inteligente para la cotización de catálogos de materiales eléctricos en Guayaquil, mediante WhatsApp Cloud API, Gemini y SQLite WAL.	**Hipótesis General (HG):** El agente conversacional con recuperación local sobre SQLite permite alcanzar una exactitud en cotizaciones superior al 95 % y latencia menor a 4.0 s bajo consumo contenido en la nube.	**Variable Independiente (VI):** Agente conversacional inteligente con recuperación local determinista sobre SQLite.	- Tiempo de respuesta de extremo a extremo (T_{resp} en ms). - Utilización de memoria RAM del servicio (MB). - Ocupación de CPU (%).	**Técnicas:** - Telemetría automatizada en servidor AWS. - Pruebas de carga sintéticas. **Instrumentos:** - Scripts de benchmarking HTTP (k6 / wrk). - Registro de logs estructurados.
Sistematización P1: ¿Cuáles son los requerimientos técnicos y las técnicas RAG óptimas para catálogos multimarca?	**Objetivo Específico 1 (O1):** Analizar los requerimientos comerciales, catálogos multimarca y técnicas RAG reportadas en literatura (2020–2026).	**Hipótesis Específica 1 (H1):** La estructuración relacional indexada en SQLite permite consultas de catálogo en menos de 100 ms.	**Variable Dependiente (VD):** Eficiencia y exactitud fáctica en el asesoramiento y cotización de suministros eléctricos.	- Tiempo de ejecución de consulta SQL (ms). - Tasa de recuperación de SKU relevantes (%).	**Técnicas:** - Revisión sistemática de literatura. - Entrevista técnica a asesores de venta. **Instrumentos:** - Guía de entrevista semiestructurada. - Matriz de extracción bibliográfica.
Sistematización P2: ¿Cómo diseñar una arquitectura ligera en .NET 8 que integre WhatsApp, Gemini y SQLite con memoria de sesión?	**Objetivo Específico 2 (O2):** Implementar un prototipo de software en .NET 8 con recuperación SQLite, orquestación Gemini y WhatsApp Cloud API.	**Hipótesis Específica 2 (H2):** La arquitectura asíncrona en .NET 8 gestiona webhooks concurrentes con memoria de proceso inferior a 250 MB.	**Unidad de Análisis:** Distribuidora Power Electrimk y conjunto de consultas de prueba de clientes.	- Concurrencia de sesiones simultáneas. - Consumo medio de memoria RAM en .NET (MB).	**Técnicas:** - Inspección de procesos de software. - Perfilado de memoria. **Instrumentos:** - Profiler de .NET (dotnet-counters, dotnet-dump).
Sistematización P3: ¿Cuál es el efecto de la recuperación local frente al modelo generativo aislado sobre la exactitud y latencia?	**Objetivo Específico 3 (O3):** Evaluar el desempeño del prototipo (T_{resp}, exactitud de precios, consumo de recursos) comparando con/sin RAG.	**Hipótesis Específica 3 (H3):** El agente con RAG local exhibe menor tasa de alucinación y exactitud de precios significativamente mayor ($p < 0.05$).	**Población y Muestra:** Batería de $N = 50$ casos de prueba estructurados de cotización técnica.	- Exactitud de cotización (Acc_{cot} en %). - Tasa de alucinación (H_{rate} en %). - Valor p de significancia estadística.	**Técnicas:** - Ensayo experimental comparativo (control vs. experimental). **Instrumentos:** - Matriz de cotejo de precios vs. catálogo base. - Paquete estadístico R / Python scipy.

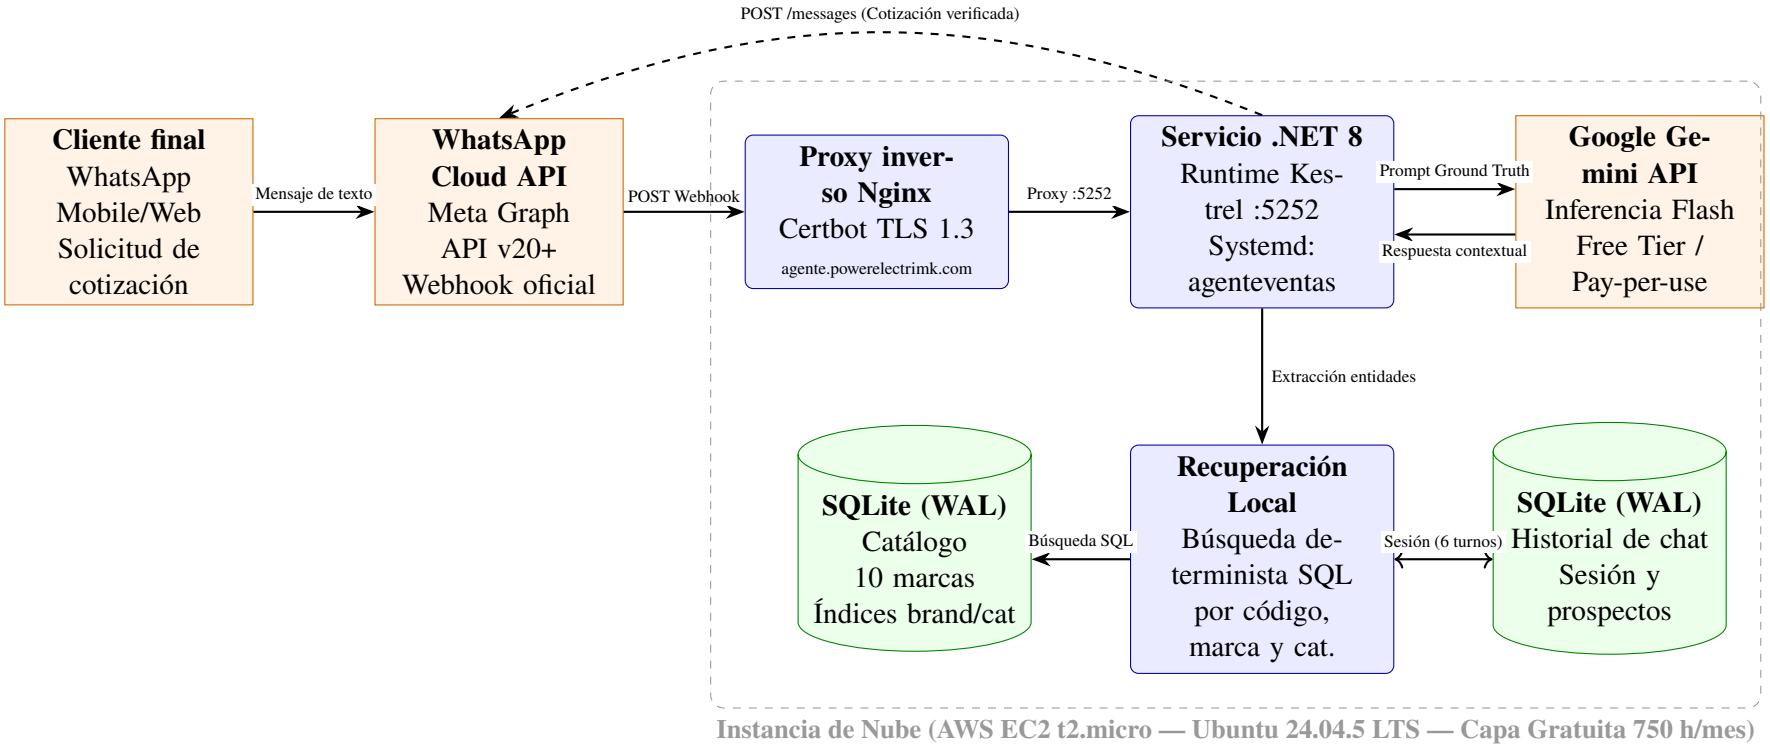
Nota. Matriz adaptada de la plantilla oficial de consistencia de la investigación UPS Sede Guayaquil (P69).

11.3. Anexo 3: Diagrama de arquitectura de software y flujo de procesamiento

En la Figura 4 se ilustra la arquitectura de componentes y el flujo secuencial de procesamiento de mensajes del agente conversacional, detallando la interacción entre los servicios externos de mensajería e inferencia y la infraestructura de cómputo local en la nube.

Figura 4

Arquitectura integral del agente conversacional con recuperación local de catálogos



Nota. Diagrama arquitectónico del flujo de ejecución desacoplado entre el webhook de mensajería, el backend en .NET 8, el almacenamiento local embebido y el servicio de inferencia en la nube.

11.4. Anexo 4: Repositorio de código abierto y transparencia de datos

En estricto cumplimiento con el criterio de evaluación ABET IV.3 (Ética, Impacto y Reproducibilidad en Ingeniería), se formaliza el compromiso de acceso abierto a los artefactos de investigación:

1. **Repositorio de código fuente:** Todo el código fuente del microservicio backend, los scripts de migración y estructuración de catálogos y las herramientas de benchmarking automatizado serán gestionados y publicados en el repositorio institucional público de GitHub:

   https://github.com/vtotoy/agente-ventas-power

2. **Licenciamiento de software:** El software se distribuye bajo los términos de la licencia de código abierto **MIT License**, permitiendo la auditoría por pares, su reutilización académica y la transferencia tecnológica sin fines de lucro hacia otras micro y pequeñas empresas ecuatorianas.

3. **Gobernanza y anonimización de datos (LOPDP):** Los conjuntos de datos de prueba, trazas de telemetría y transcripciones experimentales publicadas en el repositorio se someterán a un protocolo riguroso de anonimización irreversible. Los números telefónicos y nombres de personas naturales son sustituidos por identificadores sintéticos disociados (*UUIDs*), garantizando el pleno acatamiento de la Ley Orgánica de Protección de Datos Personales del Ecuador.

4. **Guía de reproducibilidad computacional:** El repositorio incluye las directrices técnicas, el archivo `Dockerfile` de compilación multicapa y los procedimientos documentados paso a paso para desplegar el entorno de evaluación sobre cualquier distribución Linux con el runtime de .NET 8 y SQLite preinstalados.