Universidad Politécnica Salesiana

Sede Guayaquil

CARRERA: COMPUTACIÓN

ANTEPROYECTO

Previo a la obtención del título de Ingeniero en Ciencias de la Computación

TÍTULO

Desarrollo de un agente inteligente para la atención comercial y cotización de materiales eléctricos en Guayaquil

AUTORES

Victor Jesus Totoy Iza

Rodolfo Damián Seminario Murillo

TUTOR

Ing. Joe Llerena Izquierdo, M.Sc., Ph.D.

Guayaquil, noviembre del 2026

Índice

1 Tema del Trabajo de Titulación 1

2 Antecedentes 1

3 Justificación 3

4 Objetivos 5
4.1 Objetivo General 5
4.2 Objetivos Específicos 5

5 Marco hipotético o preguntas de investigación 6
5.1 Preguntas de investigación 6
5.2 Hipótesis de investigación 6

6 Marco teórico referencial 7
6.1 Agentes conversacionales en la atención comercial 7
6.2 Modelos generativos de lenguaje extenso y arquitectura de agentes 8
6.3 Recuperación aumentada, bases de datos embebidas y estándares de ingeniería . 8

7 Metodología / Propuesta de desarrollo 9

8 Cronograma de actividades 12

9 Proyectos de investigación vinculados 13

10 Presupuesto del Proyecto de Titulación 14

11 Anexos 21
11.1 Anexo 1: Árbol de problemas y objetivos (Metodología 5W+H) 21
11.2 Anexo 2: Matriz de consistencia metodológica de la investigación 23
11.3 Anexo 3: Diagrama de arquitectura de software y flujo de procesamiento 25
11.4 Anexo 4: Repositorio de código abierto y transparencia de datos 26

Índice de figuras

1 Diagrama de flujo de las fases de la metodología de investigación 11
2 Árbol de problemas de la atención comercial en distribuidoras eléctricas 21
3 Árbol de objetivos de la solución de ingeniería de software 22
4 Arquitectura integral del agente inteligente para la atención comercial con recuperación local de catálogos 25

Índice de tablas

1 Comparativa de trabajos previos en sistemas conversacionales para comercio técnico 3
2 Cronograma de hitos del programa de titulación 12
3 Plan de actividades por fases del proyecto de titulación 13
4 Presupuesto detallado y valoración económica del proyecto de titulación 15
5 Análisis operativo de servicios de nube: Capa Gratuita vs. Régimen Comercial de Pago 16
6 Matriz de consistencia metodológica de la investigación (Formato Institucional UPS P69) 24

1. Tema del Trabajo de Titulación

Desarrollo de un agente inteligente para la atención comercial y cotización de materiales eléctricos en Guayaquil

2. Antecedentes

Actualmente, el comercio conversacional a través de plataformas de mensajería instantánea constituye el canal preponderante de captación y venta técnica para las pequeñas y medianas empresas comerciales (Adam et al., 2021; Adamopoulou & Moussiades, 2020; Følstad & Brandtzæg, 2020; Luo et al., 2019). En el sector de la distribución de materiales eléctricos e ingeniería en la ciudad de Guayaquil, contratistas independientes, técnicos electricistas y empresas constructoras demandan cotizaciones inmediatas y continuas que involucran especificaciones rigurosas de marcas líderes como Schneider Electric, Siemens, Legrand, Centelsa y ABB. No obstante, este proceso se gestiona tradicionalmente de forma manual mediante asesores de mostrador que deben consultar dispersos catálogos en formato PDF y extensas hojas de cálculo de precios. Esta modalidad ocasiona tiempos de espera para el cliente que oscilan entre 2 y 8 horas hábiles, lo cual provoca una pérdida directa de oportunidades comerciales estimada entre el 20 % y el 35 % de las solicitudes recibidas, dado que los compradores migran rápidamente hacia competidores con mayor celeridad de respuesta. De no implementarse mecanismos tecnológicos que sistematicen la atención, las distribuidoras enfrentan un incremento sostenido de sus costos operativos y el deterioro gradual de la fidelización de sus clientes (Llerena-Izquierdo & Ayala-Carabajo, 2022; Llerena-Izquierdo & Ayala-Carabajo, 2025).

Diversas investigaciones previas abordaron la automatización del servicio al cliente mediante sistemas conversacionales computacionales. Adamopoulou y Moussiades (2020) documentaron la evolución histórica de los agentes conversacionales, demostrando que las arquitecturas iniciales basadas en árboles de decisión y expresiones regulares presentan una rigidez severa ante la variabilidad del lenguaje natural no contemplado en su diseño. Adam et al. (2021) y Sands et al. (2021) evidenciaron que la incorporación de señales de interacción antropomórfica y presencia social en asistentes virtuales incrementa la tasa de adopción y cumplimiento de los usuarios, mientras que Ashfaq et al. (2020) y Han (2023) modelaron los determinantes de satisfacción e intención de compra en entornos de comercio electrónico conversacional. Con la introducción de la arquitectura Transformer por Vaswani et al. (2017), los Modelos de Lenguaje Extenso (LLM) transformaron el procesamiento del lenguaje; consecuentemente, Wang et al. (2024) sistematizaron su aplicación en agentes autónomos capaces de inferir intenciones complejas y orquestar herramientas. Sin embargo, Ji et al. (2023) y Huang et al. (2024) demostraron que los modelos generativos producen alucinaciones probabilísticas al responder sobre datos no presentes en su entrenamiento, lo que resulta crítico en transacciones comerciales al alterar precios o inventarios. Para mitigar esta debilidad, Guu et al. (2020) y Lewis et al. (2020) formularon los fundamentos de la Generación Aumentada por Recuperación (RAG), mientras que

Borgeaud et al. (2022) y Gao et al. (2023) profundizaron en modelos de recuperación densa sobre corpus masivos. Asimismo, mientras que Wu et al. (2023) plantearon esquemas multiagente que requieren clústeres de servidores y múltiples llamadas secuenciales a los modelos, y Asai et al. (2024) propusieron marcos de auto-reflexión computacionalmente densos, Llerena-Izquierdo, Mendez-Reyes et al. (2024) y Llerena-Izquierdo, Fiallos-Vargas et al. (2024) validaron en el entorno local la factibilidad y eficacia de emplear modelos fundacionales modernos de alta velocidad (Gemini) en procesos aplicados.

A pesar de los aportes documentados, la literatura científica evidencia una brecha tecnológica sustancial en el despliegue de agentes inteligentes en entornos de recursos computacionales restringidos para empresas comerciales. Los sistemas RAG convencionales dependen de bases de datos vectoriales y modelos de incrustación de alta demanda de memoria RAM y GPU, lo que imposibilita su alojamiento en servidores de entrada en la nube de bajo costo (instancias con 1 GB de RAM). De igual forma, las arquitecturas multiagente incrementan la latencia a más de diez segundos por interacción, excediendo los límites estrictos de los webhooks de Meta y afectando la experiencia del usuario. No se ha evidenciado un modelo que resuelva la recuperación estructurada sobre catálogos técnicos multimarca donde la búsqueda precisa por atributos deterministas (código de fábrica, amperaje, calibre y marca) garantice cero alucinaciones de precios y conserve la memoria contextual de cada cliente en un único microservicio ligero.

Para resolver esta brecha, el presente proyecto técnico desarrollará un agente inteligente para la atención comercial y cotización de materiales eléctricos que integrará un modelo generativo multimodal con un mecanismo de recuperación local de catálogos estructurados sobre una base de datos embebida SQLite con registro en modo Write-Ahead Logging (Gaffney et al., 2022). El agente operará como un servicio web asíncrono en .NET 8 conectado a la API oficial de WhatsApp Cloud y al modelo fundacional Gemini, tomando como escenario experimental a la distribuidora Power Electrimk de la ciudad de Guayaquil. Siguiendo la línea de investigación de Ayala-Carabajo y Llerena-Izquierdo (2026) sobre dominios cognitivos y sistemas inteligentes, la propuesta automatiza el embudo de ventas técnicas anclando deterministamente cada consulta a registros verificables de catálogo, garantizando precios exactos, latencia de respuesta sub-cuatro segundos, trazabilidad del cliente y derivación asistida hacia asesores comerciales humanos con costos de infraestructura mínimos. En la Tabla 1 se presenta el análisis comparativo del estado del arte.

Tabla 1
Comparativa de trabajos previos en sistemas conversacionales para comercio técnico

Autor	Técnica base	Ventajas identificadas	Limitaciones operativas
Adamopoulou y Moussiades (2020)	Árboles de decisión y patrones regex	Respuestas deterministas y predecibles	Rigidez ante variaciones de lenguaje natural
Adam et al. (2021)	Chatbot con señales antropomórficas	Alta aceptación y fluidez de usuario	Carece de verificación de datos técnicos y precios
Wang et al. (2024)	Agentes autónomos basados en LLM	Comprensión semántica flexible y herramientas	Alucinaciones factuales en cotizaciones exactas
Lewis et al. (2020); Gao et al. (2023)	RAG tradicional con base vectorial	Anclaje de respuestas a documentos extensos	Alto consumo de RAM/GPU y búsqueda inexacta
Wu et al. (2023)	Orquestación multiagente distribuida	Resolución colaborativa de tareas complejas	Alta latencia acumulada y costos prohibitivos

Nota. Elaboración propia a partir de la revisión sistemática de literatura sobre arquitecturas conversacionales.

3. Justificación

La presente investigación se justifica por la imperiosa necesidad de transformar el proceso operativo de cotización y asesoramiento técnico de materiales eléctricos en las distribuidoras comerciales que gestionan sus ventas a través de mensajería instantánea. En el mercado ecuatoriano de suministros eléctricos, la inmediatez y la certeza técnica determinan el cierre comercial; no obstante, el personal de ventas invierte una fracción considerable de su jornada laboral consultando hojas de cálculo, archivos PDF desactualizados y listas impresas para responder preguntas repetitivas sobre marcas, calibres, amperajes y precios. La incorporación de un agente inteligente de ventas comerciales capaz de guiar al cliente en el embudo técnico, interpretar requerimientos conversacionales y emitir cotizaciones fácticas en tiempo real con datos verificables confiere una ventaja competitiva directa y mitiga el riesgo de pérdida de clientes por demoras en la atención.

Desde una perspectiva técnica y científica, la integración de un modelo de lenguaje generativo con una capa de recuperación local estructurada resuelve de manera determinante el fenómeno de las alucinaciones probabilísticas y la inconsistencia fáctica en modelos fundacionales (Huang et al., 2024; Ji et al., 2023; Lewis et al., 2020; Tonmoy et al., 2024). En el campo de los suministros eléctricos, las alucinaciones no constituyen meros descuidos estilísticos; la invención de un calibre de conductor indebido, la alteración de la curva de disparo de un disyuntor termomagnético o la cita de un precio desactualizado acarrean riesgos severos de sobrecarga eléctrica, cortocircuito, siniestros materiales o pérdidas financieras. Si bien los modelos fundacionales como Gemini poseen una alta capacidad de comprensión sintáctica y semántica en lenguaje natural, carecen de acceso autónomo a inventarios específicos y dinámicos.

El empleo del motor relacional embebido SQLite con registro de escritura anticipada (WAL) permite realizar consultas deterministas de alta velocidad directamente en el espacio de memoria del proceso, inyectando los datos fácticos verificados (*ground truth*) dentro del contexto de inferencia. Esto erradica las discrepancias de catálogo y evita el despliegue de bases de datos vectoriales pesadas que demandan hardware costoso (Gaffney et al., 2022). Asimismo, la implementación del servicio en .NET 8 con patrones asíncronos bajo el paradigma de microservicios ligeros orientados a la nube garantiza la capacidad de atender múltiples sesiones simultáneas bajo consumo mínimo de memoria, en concordancia con los principios de desarrollo cloud-native y software asistido por inteligencia artificial promovidos en la disciplina (Kratzke & Quint, 2017; Llerena-Izquierdo, Fiallos-Vargas et al., 2024; Newman, 2021; Taibi et al., 2017).

En el ámbito social, productivo y de política pública, el proyecto se alinea de forma explícita con los objetivos del Plan Nacional de Desarrollo de la República del Ecuador, en sus ejes orientados a la transformación digital, la modernización de los encadenamientos productivos y el fortalecimiento de la competitividad de las micro, pequeñas y medianas empresas (MIPYMES). La distribuidora Power Electrimk, ubicada en la ciudad de Guayaquil, se beneficiará de una operatividad continua 24/7, canalizando prospectos calificados hacia sus ejecutivos de venta. Al mismo tiempo, los maestros eléctricos, contratistas y usuarios finales obtendrán especificaciones técnicas normalizadas y precios referenciales transparentes sin barreras geográficas ni demoras de atención.

En conformidad con los criterios de diseño en ingeniería (Criterio ABET 1), la solución se encuentra sujeta a cuatro restricciones formales de diseño:

1. **Restricción de latencia operativa:** El tiempo total de procesamiento y respuesta de extremo a extremo no deberá superar los 4.0 segundos por interacción, garantizando una experiencia fluida y evitando cancelaciones o reintentos en los webhooks de WhatsApp Cloud API.

2. **Restricción de hardware y costo de infraestructura:** El sistema deberá operar de manera estable en una instancia de entrada en la nube de bajos recursos (computación contenida a 1 vCPU y 1 GB de memoria RAM, equivalente a AWS EC2 t2.micro), manteniendo los costos operativos de infraestructura por debajo de 15.00 USD mensuales.

3. **Restricción de cumplimiento normativo y privacidad:** El manejo de identificadores de usuario, números telefónicos y registros de conversaciones deberá cumplir estrictamente con los mandatos de la Ley Orgánica de Protección de Datos Personales (LOPDP) de la República del Ecuador, empleando transporte seguro bajo TLS 1.3 y disociación de datos de contacto.

4. **Restricción de exactitud e integridad de catálogo:** Se impone una tolerancia de error nula (0 %), supeditando cualquier emisión de cotización a la coincidencia determinista con los registros oficiales de la base de datos local.

El alcance del proyecto de titulación comprende la recopilación y estructuración de los catálogos multimarca de la distribuidora, el diseño del esquema relacional local, el desarrollo del servicio backend en .NET 8 con integración a WhatsApp Cloud API y al modelo generativo Gemini, el despliegue productivo en una instancia Linux de AWS con proxy inverso Nginx y certificados TLS, y la evaluación experimental cuantitativa de latencia, exactitud y consumo de recursos. Se delimita la solución a la asesoría técnica de compatibilidad, emisión de cotizaciones referenciales formales y captura estructurada de prospectos. Asimismo, la arquitectura de software se diseña de manera modular y extensible bajo principios SOLID, sentando las bases contractuales para una segunda fase tecnológica post-titulación que incorporará reconocimiento multimodal de piezas por imágenes fotográficas con Gemini Flash Vision, seguimiento comercial automatizado (*follow-up*), derivación asistida a asesores humanos mediante el patrón *State* y sincronización bidireccional con sistemas CRM. Quedan explícitamente excluidos del alcance del anteproyecto la recaudación de pagos directos mediante pasarelas financieras, la emisión de facturación electrónica reglamentada por el SRI y la conexión nativa con sistemas ERP legados, salvaguardando la viabilidad de ejecución dentro del límite de 400 horas académicas.

4. Objetivos

4.1. Objetivo General

Desarrollar un agente inteligente para la atención comercial y cotización de materiales eléctricos en Guayaquil, mediante la integración de modelos generativos y recuperación relacional determinista sobre catálogos técnicos para garantizar cotizaciones fácticas en la distribuidora Power Electrimk.

4.2. Objetivos Específicos

De conformidad con los niveles taxonómicos de Bloom y las directrices metodológicas de titulación en ingeniería computacional de la Universidad Politécnica Salesiana, se establecen los siguientes objetivos específicos:

- **Analizar** los requerimientos operativos de atención comercial y la estructura de los catálogos técnicos multimarca en la distribuidora Power Electrimk, determinando los atributos esenciales de inventario y las especificaciones de ingeniería requeridas para el agente de ventas.
- **Implementar** un prototipo de software en arquitectura ligera sobre .NET 8 que integre de forma desacoplada la API oficial de WhatsApp Cloud, el modelo fundacional Gemini y un motor de base de datos embebido SQLite con registro en modo Write-Ahead Logging para consultas deterministas y persistencia de memoria de sesión comercial.
- **Evaluar** el desempeño computacional y la efectividad operativa del prototipo mediante pruebas experimentales controladas que contrasten el agente con recuperación local

frente al modelo sin recuperación, cuantificando la exactitud de precios y referencias técnicas, la tasa de mitigación de alucinaciones, la latencia en percentil P95 y el consumo de recursos en la nube.

5. Marco hipotético o preguntas de investigación

En concordancia con la matriz metodológica institucional UPS P69 y los objetivos específicos planteados, se formulan las preguntas de sistematización del problema y las correspondientes hipótesis de ingeniería que guiarán la investigación experimental.

5.1. Preguntas de investigación

Pregunta General (PG). ¿En qué medida un agente inteligente para la atención comercial y cotización de materiales eléctricos en Guayaquil, basado en modelos generativos y recuperación relacional determinista, mejora la exactitud de precios, la latencia de respuesta y la eficiencia de recursos computacionales en el proceso de ventas de la distribuidora Power Electrimk?

Pregunta Específica 1 (P1). ¿Cuáles son los requerimientos comerciales y qué estructura de normalización de datos en catálogos técnicos multimarca se requiere para soportar consultas deterministas de inventario y cotización en la distribuidora Power Electrimk?

Pregunta Específica 2 (P2). ¿Cómo diseñar e implementar una arquitectura de microservicio ligera en .NET 8 que orqueste la mensajería asíncrona de WhatsApp Cloud API, la inferencia generativa de Gemini y la recuperación local en SQLite preservando la memoria conversacional comercial bajo un consumo contenido de recursos?

Pregunta Específica 3 (P3). ¿En qué medida la incorporación del mecanismo de recuperación determinista local mitiga la tasa de alucinación, optimiza la exactitud fáctica de cotizaciones y reduce la latencia en percentil P95 frente al modelo generativo operando de manera aislada sin recuperación contextual?

5.2. Hipótesis de investigación

Hipótesis General (HG). La implementación de un agente inteligente para la atención comercial y cotización de materiales eléctricos en Guayaquil con recuperación fáctica local sobre catálogos estructurados en SQLite permite optimizar el embudo de ventas técnicas en Power Electrimk, alcanzando una exactitud de precios y referencias técnicas superior al 95 %, una tasa de alucinación fáctica nula (0 %), y una latencia en percentil P95 inferior a 4.0 segundos, con un perfil de consumo de memoria RAM inferior a 250 MB en infraestructura virtual de entrada en la nube.

Hipótesis Específica 1 (H1). El levantamiento y la normalización relacional de los atributos esenciales del catálogo multimarca estructurado en SQLite permiten resolver consultas de inven-

tario comercial con tiempos de ejecución en base de datos (T_{sql}) inferiores a 100 milisegundos con 100 % de integridad en campos críticos (código de fábrica, precio y marca).

Hipótesis Específica 2 (H2). Una arquitectura asíncrona desacoplada en .NET 8 con persistencia de sesiones comerciales permite procesar las ráfagas de webhooks entrantes de WhatsApp Cloud API sin bloqueos de concurrencia, manteniendo la utilización de memoria del proceso por debajo de 250 megabytes.

Hipótesis Específica 3 (H3). El agente comercial con recuperación fáctica determinista exhibirá una tasa de alucinación significativamente menor ($H_{rate} = 0\,\%$, $p < 0{,}05$) y una exactitud de cotización ($Acc_{cot} \geq 95\,\%$) estadísticamente superior en comparación con el modelo generativo operando en modalidad directa sin recuperación contextual.

6. Marco teórico referencial

Esta sección fundamenta conceptualmente la formulación del artefacto de software propuesto, estructurando los conocimientos de manera deductiva desde los paradigmas de interacción hasta los mecanismos de persistencia y los estándares de ingeniería de software que rigen su implementación. Los contenidos se organizan en torno a tres constructos esenciales: los agentes conversacionales en la atención comercial, los modelos generativos de lenguaje extenso, y las técnicas de recuperación aumentada sobre motores embebidos.

6.1. Agentes conversacionales en la atención comercial

Un agente conversacional es un sistema de software diseñado para emular la interacción humana mediante procesamiento de lenguaje natural, facilitando la ejecución de tareas o la provisión de información de manera interactiva (Adamopoulou & Moussiades, 2020). Históricamente, las primeras arquitecturas comerciales se fundamentaron en árboles de decisión y cotejo de patrones basados en reglas sintácticas fijas; si bien estos sistemas exhiben un comportamiento estrictamente predecible, sufren de una fragilidad intrínseca ante variaciones semánticas, errores tipográficos o expresiones idiomáticas no contempladas por los analistas (Følstad & Brandtzæg, 2020). En el entorno del comercio electrónico conversacional, la percepción de naturalidad, comprensión contextual y empatía técnica condiciona directamente la satisfacción, la confianza del consumidor y su predisposición para culminar una transacción de compra (Adam et al., 2021; Ashfaq et al., 2020; Sands et al., 2021). Asimismo, estudios empíricos en mercadotecnia digital demuestran que la pericia percibida del asistente y la transparencia en su condición de agente artificial inciden significativamente en la intención de compra y en la fidelización del cliente técnico (Han, 2023; Luo et al., 2019). Cuando se trata de suministros técnicos como materiales eléctricos, el usuario no solo busca conocer un precio, sino que requiere una consulta orientativa sobre compatibilidad de voltaje, calibres conductores y disponibilidad de marcas sustitutas. Esta complejidad lingüística y semántica hace inviable el uso exclusivo de árboles estáticos y motiva

la integración de modelos generativos avanzados en el núcleo de procesamiento del agente.

6.2. Modelos generativos de lenguaje extenso y arquitectura de agentes

Los modelos de lenguaje extenso (LLM) contemporáneos se basan en la arquitectura Transformer, cuyo mecanismo de autoatención captura dependencias globales de significado a lo largo de secuencias textuales complejas (Vaswani et al., 2017). Entrenados sobre volúmenes masivos de datos textuales, estos modelos exhiben capacidades emergentes para la inferencia contextual, el seguimiento riguroso de directrices delimitadas en mensajes de sistema (*system prompts*) y la adopción de roles comerciales especializados (Wang et al., 2024). No obstante, la naturaleza fundamentalmente probabilística de los LLM induce el fenómeno conocido como alucinación, en el cual el modelo produce aseveraciones sintácticamente coherentes pero fácticamente falsas o inexistentes en la realidad objetiva (Huang et al., 2024; Ji et al., 2023). Recientes revisiones sistemáticas categorizan las alucinaciones en intrínsecas (contradicción directa de la fuente provista) y extrínsecas (invención de hechos no verificables), atribuyendo su origen a sesgos de preentrenamiento y fallas en la alineación paramétrica (Tonmoy et al., 2024). En un entorno industrial o comercial de distribución eléctrica, la invención de un precio unitario, una capacidad de interrupción inexistente o una certificación técnica errónea acarrea graves perjuicios comerciales y legales. Por consiguiente, resulta imperativo gobernar el comportamiento generativo mediante verificación de cadenas de conocimiento y mecanismos de anclaje determinista (*grounding*) (Dhuliawala et al., 2023), conocidos formalmente como generación aumentada por recuperación.

6.3. Recuperación aumentada, bases de datos embebidas y estándares de ingeniería

El paradigma de generación aumentada por recuperación (*Retrieval-Augmented Generation*, RAG) constituye una metodología híbrida que desacopla la memoria paramétrica del modelo de lenguaje de la fuente fáctica de verdad, consultando un almacén de datos estructurado o no estructurado antes de sintetizar la respuesta final (Borgeaud et al., 2022; Gao et al., 2023; Guu et al., 2020; Lewis et al., 2020). Si bien propuestas recientes exploran mecanismos avanzados de auto-reflexión y re-evaluación iterativa (*Self-RAG*) (Asai et al., 2024), tales enfoques imponen una penalización severa de latencia y costo computacional. En el contexto de catálogos de materiales eléctricos, donde las entidades poseen atributos inequívocos como código de parte, amperaje, marca y curva de operación, la recuperación basada en esquemas relacionales e índices lexicográficos presenta mayor precisión y predictibilidad que las representaciones vectoriales densas, evitando discrepancias de redondeo y falsos positivos semánticos. Para optimizar esta búsqueda en lenguaje natural, se incorpora el motor de búsqueda de texto completo (*Full-Text Search*, FTS5) con ponderación probabilística BM25 (*Best Matching 25*) (Robertson & Zaragoza, 2009), complementado con sincronización por disparadores (*triggers*) y rutinas de auto-reparación dinámica de índices en tiempo de ejecución.

Para satisfacer la restricción de hardware en entornos de bajo presupuesto computacional, el empleo de SQLite como motor embebido ofrece transacciones ACID completas dentro del mismo espacio de proceso de la aplicación, suprimiendo la sobrecarga de comunicación interproceso por sockets de red y el consumo de memoria asociado a servicios de bases de datos independientes (Gaffney et al., 2022). Al habilitar el modo de registro de escritura anticipada (*Write-Ahead Logging*, WAL), el motor soporta lecturas simultáneas altamente concurrentes sin bloquear las escrituras de actualización de catálogo o registro de sesiones. Asimismo, la estructuración del backend bajo principios de microservicios independientes y patrones *cloud-native* garantiza un despliegue desacoplado, mantenible y escalable con huella mínima de memoria en servidores virtuales de entrada (Kratzke & Quint, 2017; Newman, 2021; Taibi et al., 2017).

Asimismo, la construcción del artefacto se gobierna bajo el estándar internacional de calidad de producto software **ISO/IEC 25010:2011**, priorizando las características de adecuación funcional, eficiencia de desempeño (tiempo de respuesta y utilización de recursos), fiabilidad y seguridad (ISO/IEC, 2011). La seguridad de la información en el canal de mensajería se garantiza mediante el protocolo **TLS 1.3** (RFC 8446) para el cifrado en tránsito (Rescorla, 2018), complementado con la verificación de firmas criptográficas HMAC-SHA256 exigida por WhatsApp Cloud API para autenticar la legitimidad de cada webhook entrante. Frente a los vectores emergentes de vulnerabilidad en modelos generativos, se implementa una arquitectura de defensa en profundidad contra inyecciones de *prompt* indirectas (*Indirect Prompt Injection*) en documentos técnicos e imágenes fotográficas (Greshake et al., 2023), aplicando neutralización de inyección de fórmulas de hoja de cálculo, prevención de entidades externas XML (*XXE*), delimitación estricta de contexto y verificación de salida mediante *tokens* centinela (*canary tokens*). Estos fundamentos teóricos, metodológicos y normativos proporcionan el marco de referencia indispensable sobre el cual se articula la propuesta de desarrollo técnico descrita en la siguiente sección.

7. Metodología / Propuesta de desarrollo

La presente investigación adopta un alcance descriptivo y aplicado, bajo un enfoque metodológico mixto predominantemente cuantitativo y con un diseño cuasi-experimental de corte transversal. Según su propósito, constituye una investigación tecnológica orientada a la concepción, ingeniería y validación empírica de un artefacto de software; según el método de inferencia, es de naturaleza deductiva al derivar hipótesis operativas a partir de constructos teóricos consolidados; según la procedencia de la información, combina fuentes secundarias documentales (catálogos de fabricantes, especificaciones técnicas y literatura científica indexada) con datos primarios generados durante las pruebas automatizadas del sistema. La recolección de datos se sustentará en el registro automatizado de trazas de telemetría y métricas de rendimiento en servidor, complementado con entrevistas semiestructuradas al equipo comercial para el levantamiento de requerimientos de dominio (Llerena-Izquierdo & Ayala-Carabajo, 2022).

El desarrollo del proyecto se estructurará rigurosamente en cinco fases consecutivas e iterativas:

En la **Fase 1: Revisión bibliográfica y análisis de requerimientos**, se llevará a cabo una revisión bibliográfica exhaustiva fundamentada en directrices metodológicas para ingeniería de software y la recopilación de literatura científica reciente en bases de datos indexadas (Scopus, IEEE Xplore, ACM y Web of Science). Se analizarán investigaciones sobre agentes conversacionales, modelos de lenguaje extenso y técnicas de recuperación aumentada (RAG). De forma paralela, se levantarán los requerimientos funcionales y técnicos con el personal comercial de la distribuidora Power Electrimk, estructurando un catálogo industrial multimarca inicial superior a 600 referencias activas y verificadas de fabricantes líderes (Schneider Electric y Siemens) distribuidas en seis líneas esenciales: distribución de potencia y modular, control y maniobra de motores, automatización programable (PLCs y módulos lógicos), variadores de frecuencia, fuentes de poder y unidades de mando/señalización.

En la **Fase 2: Diseño de la arquitectura propuesta**, se definirá la arquitectura de software en capas basada en microservicios ligeros, estableciendo el esquema relacional en SQLite optimizado bajo modo WAL y dotado de una capa de búsqueda de texto completo (*Full-Text Search*, FTS5) con algoritmo de clasificación BM25 y rutinas de auto-reparación dinámica de índices. Se diseñará el flujo de control para la verificación y consumo de los webhooks de WhatsApp Cloud API, la arquitectura de defensa en profundidad contra inyecciones de *prompt* en documentos técnicos e imágenes fotográficas, el mecanismo de *tokens* centinela efímeros (*canary tokens*) para certificar la integridad de las directivas de sistema, y la política comercial multimarca 'solución primero, marca bajo demanda' orientada a prevenir la fatiga de decisión en el cliente (Zerega-Prado & Llerena-Izquierdo, 2022).

En la **Fase 3: Desarrollo del prototipo funcional**, se programará el servicio web en lenguaje C# sobre la plataforma .NET 8, aprovechando sus características nativas de alto rendimiento asíncrono y bajo consumo de memoria. Se implementará la lógica del embudo comercial (calificación de prospectos, asesoría técnica de compatibilidad, consulta determinista de inventario y derivación formal hacia asesores comerciales humanos sin alucinación de precios), el módulo de persistencia y contexto conversacional por número de teléfono, el pipeline de inspección segura en memoria RAM (Zero Disk) para documentos de requerimientos de proyectos (.xlsx, .csv, .pdf) con neutralización de inyección de fórmulas y entidades externas XML (XXE), el procesamiento multimodal nativo de fotografías técnicas para identificación de placas de motores y referencias legadas, el conector HTTP con autenticación Bearer hacia la API de WhatsApp, la capa de consulta relacional SQLite WAL con FTS5 y la integración con el SDK de Google Gemini para la síntesis contextual en lenguaje natural (Llerena-Izquierdo, Mendez-Reyes et al., 2024). La arquitectura se estructurará mediante interfaces desacopladas que habilitan contractualmente la integración de seguimiento automatizado de cotizaciones y sincronización con plataformas CRM en fases operativas posteriores.

En la **Fase 4: Despliegue y pruebas experimentales**, el prototipo se desplegará en una

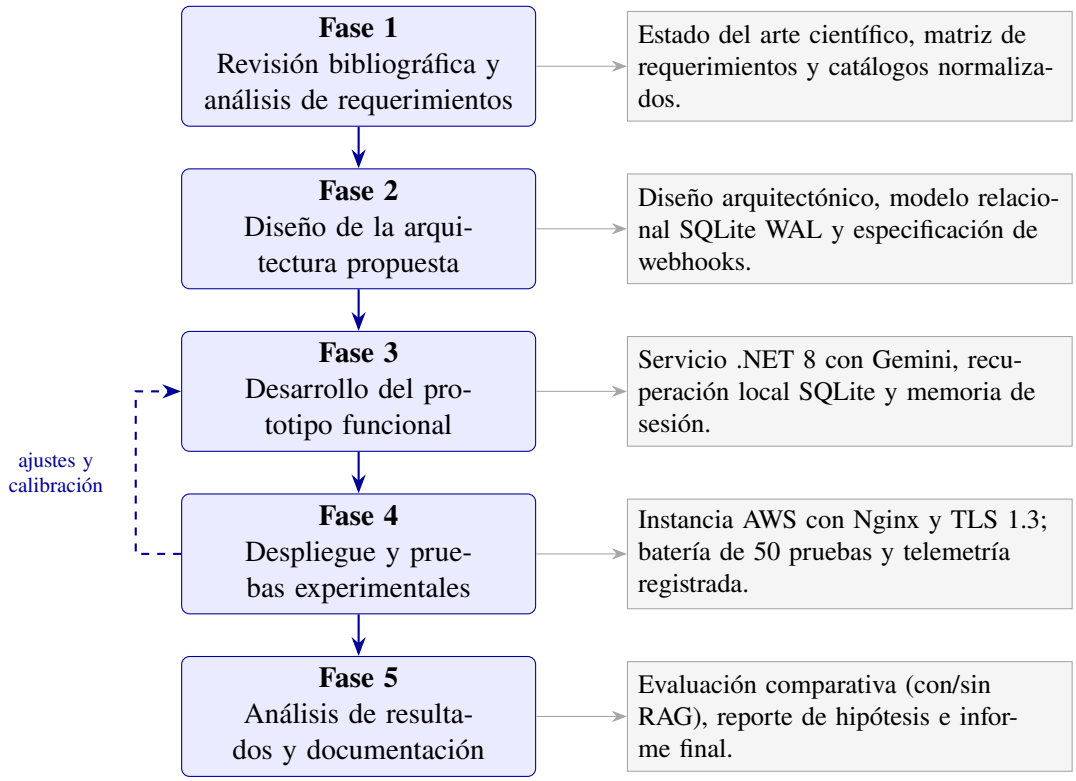
instancia virtual Linux (Ubuntu 24.04.5 LTS) en Amazon Web Services (AWS EC2 t2.micro, acogida a la Capa Gratuita de 750 horas mensuales), configurando un servidor Nginx como proxy inverso hacia el runtime Kestrel en puerto 5252, administrado por el demonio Systemd (`agenteventas.service`) y con terminación de certificados de seguridad TLS 1.3 emitidos por Certbot (Let's Encrypt) bajo el subdominio oficial `agente.powerelectrimk.com`. Se ejecutará un protocolo experimental automatizado compuesto por una batería de $N = 50$ casos de prueba estructurados (búsquedas por código exacto, por especificación técnica, por categoría y solicitudes multimarca), comparando el desempeño del agente con recuperación local determinista frente al modelo generativo sin recuperación para cuantificar la tasa de eliminación de alucinaciones en precios y referencias de catálogo.

En la **Fase 5: Análisis de resultados y documentación**, se procesarán estadísticamente las métricas de latencia de respuesta, porcentaje de exactitud en precios y referencias técnicas, tasa de alucinación y utilización de memoria RAM y procesador en el servidor. Los resultados se contrastarán contra las hipótesis de investigación planteadas, y se redactará el informe técnico final de titulación de conformidad con las directrices institucionales (Llerena-Izquierdo et al., 2026).

La Figura 1 sintetiza el flujo de fases del proyecto y los entregables correspondientes a cada etapa de la investigación.

Figura 1

Diagrama de flujo de las fases de la metodología de investigación



Nota. El diagrama ilustra la progresión secuencial de las cinco fases metodológicas y sus entregables tangibles, incluyendo el lazo de retroalimentación de ajustes entre la fase experimental y el código del prototipo.

Para la evaluación formal del sistema se han operacionalizado las siguientes métricas experimentales:

- **Latencia de respuesta ($T_{\mathbf{resp}}$):** Tiempo total transcurrido en segundos desde la recepción del evento HTTP en el webhook hasta la emisión de la llamada de respuesta a la API de WhatsApp, medido con precisión de milisegundos mediante marcas de tiempo en el servidor.
- **Exactitud de cotización ($Acc_{\mathbf{cot}}$):** Porcentaje de cotizaciones emitidas donde los códigos de producto, marcas y precios unitarios coinciden exactamente con los registros vigentes del inventario oficial, definido como:

$$Acc_{\text{cot}} = \left(\frac{C_{\text{correctas}}}{C_{\text{totales}}} \right) \times 100\,\% \tag{1}$$

- **Tasa de alucinación ($H_{\mathbf{rate}}$):** Proporción de respuestas en las que el modelo generativo asevera precios inexistentes, inventa atributos de productos o recomienda ítems no catalogados en la base de datos comercial.
- **Consumo de recursos:** Perfil de utilización de memoria RAM del proceso .NET (en megabytes) y porcentaje promedio de ocupación de CPU en la instancia de nube durante ráfagas de consultas.

8. Cronograma de actividades

El desarrollo del proyecto de titulación se estructurará a lo largo de un período académico regular, ajustándose de forma estricta a los hitos de evaluación y seguimiento dispuestos por la Comisión de Titulación de la carrera, tal como se detalla en la Tabla 2.

Tabla 2
Cronograma de hitos del programa de titulación

Hito institucional	Entregable / Alcance	Fecha límite
Presentación y aprobación	Aprobación oficial del tema de titulación	30/11/2026
Hito 1 (25 %)	Estado del arte, requerimientos y catálogos	21/12/2026
Hito 2 (50 %)	Diseño arquitectónico y esquema de datos	25/01/2027
Hito 3 (75 %)	Prototipo funcional desplegado en la nube	01/03/2027
Hito 4 (100 %)	Evaluación experimental e informe final	05/04/2027

Nota. Cronograma oficial de hitos académicos y ponderaciones de avance de acuerdo con la planificación de la Universidad Politécnica Salesiana.

Para garantizar la culminación exitosa de los objetivos planteados dentro del límite normativo de 400 horas de dedicación estudiantil, se presenta en la Tabla 3 el desglose pormenorizado de actividades por cada una de las cinco fases de la investigación, indicando su carga

horaria estimada, fechas de inicio y culminación, y los responsables asignados.

Tabla 3
Plan de actividades por fases del proyecto de titulación

Actividad	Horas	Inicio	Fin	Responsables
Fase 1: Revisión bibliográfica y análisis de requerimientos				
Revisión sistemática de literatura científica	40	01/12/2026	12/12/2026	Autores
Levantamiento de requerimientos y digitalización	30	14/12/2026	21/12/2026	Autores / Tutor
Fase 2: Diseño de la arquitectura propuesta				
Diseño arquitectónico y modelado relacional SQLite	40	22/12/2026	11/01/2027	Autores
Estructuración de índices y normalización multimarca	30	12/01/2027	25/01/2027	Autores
Fase 3: Desarrollo del prototipo funcional				
Implementación del backend .NET 8 y memoria de sesión	60	26/01/2027	12/02/2027	Autores
Integración con API Gemini y WhatsApp Cloud API	40	15/02/2027	01/03/2027	Autores
Fase 4: Despliegue y pruebas experimentales				
Despliegue en AWS con Nginx TLS y batería de pruebas	60	02/03/2027	19/03/2027	Autores
Fase 5: Análisis de resultados y documentación				
Análisis estadístico de telemetría y redacción del informe	60	20/03/2027	05/04/2027	Autores / Tutor
Subtotal de horas planificadas	360			
Horas de contingencia y ajustes (10 %)	40			
Total planificado	**400**			

Nota. Distribución del esfuerzo de ingeniería en 360 horas de ejecución técnica y 40 horas de contingencia para imprevistos o ajustes experimentales, completando las 400 horas reglamentarias.

La articulación entre el plan de actividades (Tabla 3) y los hitos institucionales (Tabla 2) asegura un avance disciplinado y continuo, permitiendo la verificación temprana de los componentes de software antes de la fase de evaluación experimental definitiva.

9. Proyectos de investigación vinculados

El presente trabajo de titulación, desarrollado por los estudiantes **Victor Jesus Totoy Iza** y **Rodolfo Damián Seminario Murillo**, se ejecuta bajo la dirección y tutoría del docente investigador Ing. Joe Llerena Izquierdo, M.Sc., Ph.D., y se encuentra formalmente articulado a las actividades científicas del **Grupo de Investigación en Enseñanza-Aprendizaje de las Ciencias para la Ingeniería (GIEACI)** de la Universidad Politécnica Salesiana, Sede Guayaquil.

Específicamente, los postulantes solicitan su adhesión formal al proyecto de investigación institucional titulado:

«Percepciones y dilemas éticos de estudiantes de Ingeniería frente al uso de IA generativa en el aprendizaje»

el cual se inscribe en la línea de investigación institucional de la carrera de Computación denominada: *«Integración de Tecnologías Emergentes en la Educación en Ingeniería y Sistemas Inteligentes»*.

La vinculación con dicho proyecto de investigación se fundamenta en que el desarrollo del agente conversacional no solo aborda la dimensión técnica del software y la ingeniería de datos sobre SQLite, sino que aporta evidencia empírica directa sobre los dilemas de confiabilidad, sesgo y ética algorítmica derivados del uso de modelos generativos fundacionales en entornos de interacción humana real (Ayala-Carabajo & Llerena-Izquierdo, 2026; Llerena-Izquierdo, Mendez-Reyes et al., 2024). Los hallazgos sobre alucinaciones de precios, gobernanza de datos personales bajo la LOPDP ecuatoriana y patrones de interacción en mensajería instantánea enriquecerán las publicaciones y análisis del grupo GIEACI respecto a la adopción responsable de la inteligencia artificial.

10. Presupuesto del Proyecto de Titulación

El presupuesto estimado para la ejecución integral del proyecto de titulación considera tanto la valoración formal del esfuerzo de ingeniería de software (mano de obra de los tesistas), como el dimensionamiento técnico de la infraestructura computacional en la nube, conectividad, licencias de consumo y suministros requeridos para el ciclo de vida del software. En la Tabla 4 se expone la valoración económica formal del proyecto, cuantificada conforme a precios de mercado y aranceles profesionales de desarrollo.

Tabla 4

Presupuesto detallado y valoración económica del proyecto de titulación

Categoría / Rubro	Descripción y dedicación del recurso	Costo (USD)
1. Mano de obra de ingeniería y desarrollo (Tesistas)		
Victor Jesús Totoy Iza	Arquitectura backend (.NET 8), webhooks y despliegue (200 h a $10.00/h)	2000.00
Rodolfo Damián Seminario Murillo	Esquema relacional SQLite, orquestación Gemini y pruebas (200 h a $10.00/h)	2000.00
Subtotal Mano de obra de ingeniería		*4000.00*
2. Infraestructura tecnológica, servicios y suministros directos		
Servidor en la nube (AWS EC2)	Instancia virtual Linux (t2.micro) durante 6 meses de proyecto	60.00
Nombre de dominio y gestión TLS	Dominio `powerelectrimk.com` y gestión de DNS Cloudflare (1 año)	15.00
Consumo de inferencia API Gemini	Cuota de tokens para pruebas de integración y validación ($N = 50$)	40.00
Línea telefónica comercial	Tarjeta SIM y recargas para WhatsApp Business API	25.00
Servicio de acceso a Internet	Conectividad fija de banda ancha durante 6 meses ($30.00/mes)	180.00
Impresión y encuadernación	Empastado y documentación física institucional de titulación	70.00
Fondo de contingencia	Margen para imprevistos operativos y pruebas adicionales (10 %)	40.00
Subtotal Infraestructura y suministros		*430.00*
Total general valorado del proyecto		**4430.00**

Nota. Valores expresados en dólares de los Estados Unidos de América (USD). La tarifa horaria de 10.00 USD/h se fundamenta en los valores referenciales de mercado para desarrolladores de software junior en Ecuador. Los costos directos de infraestructura y servicios (430.00 USD) y la mano de obra de investigación (4000.00 USD) son asumidos íntegramente por los autores.

Como se expone en la Tabla 4, el costo consolidado del proyecto asciende a 4430.00 USD. De este valor, el 90.3 % (4000.00 USD) corresponde a la mano de obra de ingeniería aportada por los tesistas (Victor Jesús Totoy Iza y Rodolfo Damián Seminario Murillo), cuantificada en 400 horas de dedicación conjunta (200 horas individuales) a una tarifa estandarizada de 10.00 USD por hora, representando la inversión de capital humano inherente a la formación en ingeniería en computación.

Por otra parte, desde la perspectiva operativa y financiera de la puesta en marcha, el proyecto exhibe una ventaja competitiva excepcional gracias al aprovechamiento estratégico de las **capas gratuitas** (*Free Tiers*) ofrecidas por los principales proveedores tecnológicos de nube e inteligencia artificial. Durante la etapa de investigación, desarrollo y validación experimental,

los costos computacionales de la nube y de la API de inferencia se reducen de forma efectiva a 0.00 USD. En la Tabla 5 se presenta el análisis comparativo entre los límites operativos de la Capa Gratuita y la estructura tarifaria de pago (*Pay-as-you-go*) para cuando la empresa distribuidora Power Electrimk decida escalar la solución a régimen comercial masivo.

Tabla 5

Análisis operativo de servicios de nube: Capa Gratuita vs. Régimen Comercial de Pago

Proveedor / Servicio	**Capa Gratuita (Free Tier)**	**Régimen Comercial (Pay-as-you-go)**	**Gasto Fase Tesis**
Google Gemini API (Google AI Studio)	15 RPM, 1 000 000 TPM y hasta 1 500 solicitudes/día gratuitas (*Flash*).	Entrada: \$0.075 / 1M tokens. Salida: \$0.30 / 1M tokens (≈ \$2.50/mes por 1 000 chats/día).	0.00
Amazon Web Services (AWS EC2 t2.micro)	750 horas/mes gratuitas durante 12 meses; 30 GB almacenamiento SSD EBS gp3.	On-Demand: \$0.0116/h (≈ \$8.35/mes) + \$2.40/mes almacenamiento EBS gp3.	0.00
Meta Cloud API (WhatsApp Business)	1 000 conversaciones de servicio al cliente al mes gratuitas iniciadas por usuario.	Tarifa variable por categoría de conversación (≈ \$0.008 a \$0.035 USD/chat tras superar 1 000).	0.00
Let's Encrypt / Certbot (Certificado TLS 1.3)	Certificados criptográficos SSL/TLS automatizados de renovación continua (100 % gratis).	Certificados comerciales corporativos con validación de organización (\$15.00 a \$60.00/año).	0.00
Dominio y DNS (Cloudflare / Namecheap)	DNS seguro gratuito en Cloudflare; registro de dominio de pago.	Renovación anual de dominio comercial powerelectrimk.com a precio de mercado.	15.00
Conectividad fija (Proveedor local)	No aplica capa gratuita comercial.	Tarifa residencial/comercial mensual de banda ancha simétrica (\$30.00/mes × 6 meses).	180.00
Desembolso directo real de infraestructura en fase de investigación			**195.00**

Nota. Datos oficiales recopilados de la documentación técnica y tablas de facturación de Google Cloud / Google AI Studio (2026), Amazon Web Services Free Tier y Meta for Developers. El gasto real de 195.00 USD demuestra la alta viabilidad financiera del proyecto para su validación en la distribuidora Power Electrimk.

Este análisis evidencia que la combinación de un motor embebido SQLite (modo WAL sin costo de licenciamiento) con la Capa Gratuita de Google AI Studio y el AWS Free Tier minimiza el riesgo de inversión para la distribuidora Power Electrimk, requiriendo un desembolso directo de únicamente 195.00 USD durante los seis meses de ejecución del proyecto de titulación. Si la distribuidora decidiera extender la solución a un volumen comercial de alta demanda superando los límites de la capa gratuita, el esquema de cobro por consumo de Gemini Flash garantiza

que el costo mensual de inferencia por cada 1 000 cotizaciones atendidas no excederá los 3.00 USD, lo cual consolida la sostenibilidad económica y el retorno de inversión del sistema frente a plataformas propietarias de alto costo recurrente.

Referencias Bibliográficas

Adam, M., Wessel, M., & Benlian, A. (2021). AI-based chatbots in customer service and their effects on user compliance. *Electronic Markets*, *31*(2), 427-445. https://doi.org/10.1007/s12525-020-00414-7

Adamopoulou, E., & Moussiades, L. (2020). Chatbots: History, technology, and applications. *Machine Learning with Applications*, *2*, 100006. https://doi.org/10.1016/j.mlwa.2020.100006

Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2024). Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. *The Twelfth International Conference on Learning Representations (ICLR 2024)*. https://openreview.net/forum?id=hSyW5go0v8

Ashfaq, M., Yun, J., Yu, S., & Loureiro, S. M. C. (2020). I, Chatbot: Modeling the factors to accept conversational agents for customer service. *Telematics and Informatics*, *54*, 101473. https://doi.org/10.1016/j.tele.2020.101473

Ayala-Carabajo, R., & Llerena-Izquierdo, J. (2026). Comparative Experimental Studies on Superior Cognitive Domains: AI Versus Humans. *Technologies*, *14*(1), 55. https://doi.org/10.3390/technologies14010055

Borgeaud, S., Mensch, A., Hoffmann, J., Cai, T., Rutherford, E., Millican, K., van den Driessche, G., Lespiau, J.-B., Damoc, B., Clark, A., de Las Casas, D., Guy, A., Menick, J., Ring, R., Hennigan, T., Huang, S., Maggiore, L., Jones, C., Cassirer, A., . . . Sifre, L. (2022). Improving Language Models by Retrieving from Trillions of Tokens. *Proceedings of the 39th International Conference on Machine Learning (ICML 2022)*, *162*, 2206-2240. https://doi.org/10.48550/arXiv.2112.04426

Dhuliawala, S., Komeili, M., Xu, J., Raileanu, R., Li, X., Celikyilmaz, A., & Weston, J. (2023). Chain-of-Verification Reduces Hallucination in Large Language Models. https://doi.org/10.48550/arXiv.2309.11495

Følstad, A., & Brandtzæg, P. B. (2020). Users' experiences with chatbots: findings from a large-scale survey. *Quality and User Experience*, *5*(1), 1-16. https://doi.org/10.1007/s41239-020-00024-7

Gaffney, K. P., Prammer, M., Brasfield, L., Hipp, D. R., Kennedy, D., & Patel, J. M. (2022). SQLite: Past, Present, and Future. *Proceedings of the VLDB Endowment*, *15*(12), 3535-3547. https://doi.org/10.14778/3554821.3554842

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2023). Retrieval-Augmented Generation for Large Language Models: A Survey. https://doi.org/10.48550/arXiv.2312.10997

Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., & Fritz, M. (2023). Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection. *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security*, 79-90. https://doi.org/10.1145/3605764.3623982

Guu, K., Lee, K., Tung, Z., Pasupat, P., & Chang, M.-W. (2020). REALM: Retrieval-Augmented Language Model Pre-Training. *Proceedings of the 37th International Conference on Machine Learning (ICML 2020)*, *119*, 3929-3938.

Han, M. C. (2023). The effect of AI chatbot's perceived expertise on purchase intention in e-commerce. *Journal of Retailing and Consumer Services*, *75*, 103520. https://doi.org/10.1016/j.jretconser.2023.103520

Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2024). A Survey on Hallucination in Large Language Models: Principles,

Taxonomy, Challenges, and Open Questions. *ACM Computing Surveys*, *56*(12), 1-37. https://doi.org/10.1145/3703159

ISO/IEC. (2011). ISO/IEC 25010:2011: Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — System and software quality models. https://www.iso.org/standard/35733.html

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, *55*(12), 1-38. https://doi.org/10.1145/3571730

Kratzke, N., & Quint, P.-C. (2017). Understanding Cloud-Native Applications after 10 Years of Cloud Computing: A Systematic Mapping Study. *Journal of Systems and Software*, *126*, 1-16. https://doi.org/10.1016/j.jss.2017.01.001

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*, *33*, 9459-9474.

Llerena-Izquierdo, J., & Ayala-Carabajo, R. (2022). Desarrollo de competencia investigativa de estudiantes universitarios de ingeniería en proceso de titulación: propuesta metodológica y experiencia. *Memoria Investigaciones en Ingeniería*, (23), 50-62. https://doi.org/10.36561/ING.23.5

Llerena-Izquierdo, J., & Ayala-Carabajo, R. (2025). *Guía práctica para redactar y publicar manuscritos científicos*. Ediciones Abya-Yala. https://doi.org/10.17163/abyaups.134

Llerena-Izquierdo, J., Fiallos-Vargas, I., Portugal-Gorozabel, J., & Veloz-Arce, A. (2024). Towards an experience in AI-driven development for programming applied to multimedia using Tabnine. *2024 IEEE URUCON*, 1-5. https://doi.org/10.1109/URUCON63440.2024.10850207

Llerena-Izquierdo, J., Lindao-Cacao, K., Espinoza-Rosero, G., & Carrera-Jimenez, J. (2026). Towards a Management Model for the Final Year Project in Computer Engineering in the Field of Research. En M. V. Garcia, J.-P. Reyes, C. Nuñez & C. Gordón-Gallegos (Eds.), *Proceedings of the International Conference on Computer Science, Electronics and Industrial Engineering (CSEI 2024)* (pp. 37-49). Springer Nature Switzerland. https://doi.org/10.1007/978-3-031-98890-5_3

Llerena-Izquierdo, J., Mendez-Reyes, J., Ayala-Carabajo, R., & Andrade-Martinez, C. (2024). Innovations in Introductory Programming Education: The Role of AI with Google Colab and Gemini. *Education Sciences*, *14*(12), 1330. https://doi.org/10.3390/educsci14121330

Luo, X., Tong, S., Fang, Z., & Qu, Z. (2019). Frontiers: Machines vs. Humans: The Impact of Artificial Intelligence Chatbot Disclosure on Customer Purchases. *Marketing Science*, *38*(6), 937-947. https://doi.org/10.1287/mksc.2019.1192

Newman, S. (2021). *Building Microservices: Designing Fine-Grained Systems* (2.ª ed.). O'Reilly Media.

Rescorla, E. (2018). *The Transport Layer Security (TLS) Protocol Version 1.3* (RFC N.º 8446). Internet Engineering Task Force. https://doi.org/10.17487/RFC8446

Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, *3*(4), 333-389. https://doi.org/10.1561/1500000019

Sands, S., Ferraro, C., Campbell, C., & Tsao, H.-Y. (2021). Managing the human-chatbot frontier: How social presence impacts customer satisfaction. *European Journal of Marketing*, *55*(9), 2329-2347. https://doi.org/10.1108/EJM-01-2020-0052

Taibi, D., Lenarduzzi, V., & Pahl, C. (2017). Processes, Motivations, and Issues for Migrating to Microservices: An Empirical Study. *IEEE Cloud Computing*, *4*(5), 22-32. https://doi.org/10.1109/MCC.2017.4250931

Tonmoy, S. M. T. I., Zaman, S. M. M., Jain, V., Rani, A., Rawte, V., Chadha, A., & Das, A. (2024). A Comprehensive Survey of Hallucination in Large Language Models. https://doi.org/10.48550/arXiv.2402.04055

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, *30*, 5998-6008.

Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., & Wen, J. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, *18*(6), 186345. https://doi.org/10.1007/s11704-024-40231-1

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., & Wang, C. (2023). AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. https://doi.org/10.48550/arXiv.2308.08155

Zerega-Prado, J., & Llerena-Izquierdo, J. (2022). Arquitectura de consolidación de la información para seguros de la salud mediante Big Data. *Memoria Investigaciones en Ingeniería*, (23), 18-31. https://doi.org/10.36561/ING.23.3

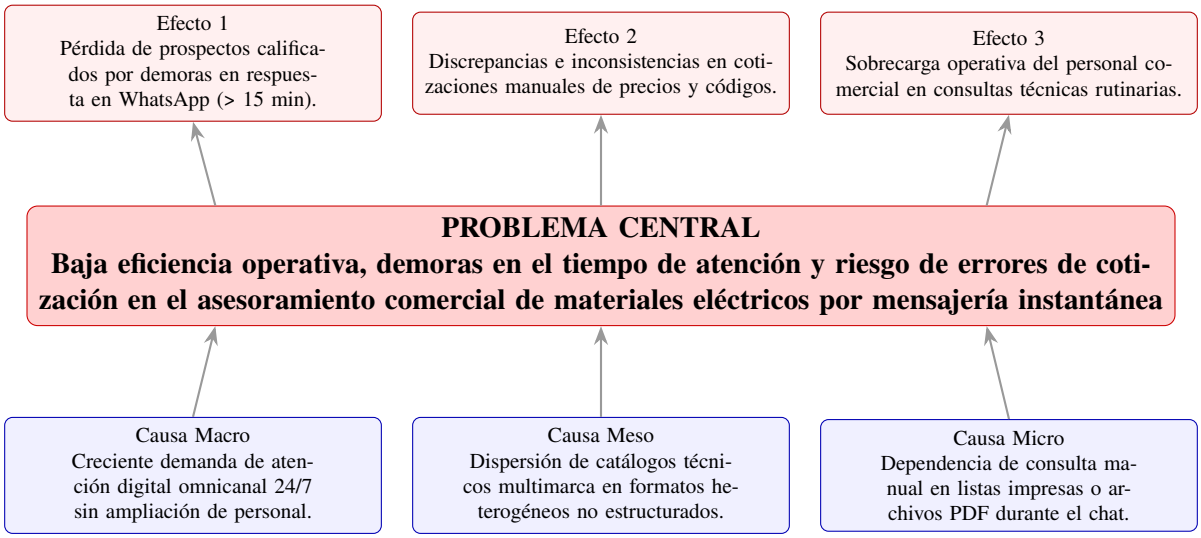
11. Anexos

11.1. Anexo 1: Árbol de problemas y objetivos (Metodología 5W+H)

De acuerdo con la guía metodológica de formulación de proyectos 5W+H de la Universidad Politécnica Salesiana, se presentan en la Figura 2 y la Figura 3 las representaciones causales del problema central y su transformación propositiva hacia los medios y fines de la solución técnica.

Figura 2

Árbol de problemas de la atención comercial en distribuidoras eléctricas



Nota. Estructura causal del problema identificada a través de la metodología 5W+H en la distribuidora Power Electrimk.

Figura 3

Árbol de objetivos de la solución de ingeniería de software



Nota. Transformación de medios y fines orientada a la ingeniería de software y la validación experimental.

11.2. Anexo 2: Matriz de consistencia metodológica de la investigación

En la Tabla 6 se detalla la Matriz de Consistencia Metodológica elaborada bajo el formato normativo institucional UPS P69, evidenciando la coherencia entre problemas, objetivos, hipótesis, variables e indicadores.

Tabla 6

Matriz de consistencia metodológica de la investigación (Formato Institucional UPS P69)

Problema	Objetivos	Hipótesis	Variables y Dimensiones	Indicadores Prioritarios	Técnicas e Instrumentos
Problema General (PG): ¿En qué medida un agente inteligente para la atención comercial y cotización de materiales eléctricos en Guayaquil, basado en modelos generativos y recuperación relacional determinista, mejora la exactitud de precios, la latencia P95 y la eficiencia de recursos en Power Electrimk?	**Objetivo General (OG):** Desarrollar un agente inteligente para la atención comercial y cotización de materiales eléctricos en Guayaquil, mediante la integración de modelos generativos y recuperación relacional determinista para garantizar cotizaciones fácticas en Power Electrimk.	**Hipótesis General (HG):** El agente con recuperación local sobre SQLite permite alcanzar una exactitud en cotización $\geq 95\,\%$, tasa de alucinación nula ($0\,\%$), latencia en P95 < 4.0 s y consumo de RAM < 250 MB en la nube.	**Variable Independiente (VI):** Modalidad de interacción conversacional con recuperación determinista local sobre catálogo estructurado.	- Exactitud de cotización ($Acc_{\text{cot}} \geq 95\,\%$). - Tasa de alucinación ($H_{\text{rate}} = 0\,\%$). - Latencia en P95 ($T_{\text{resp}} < 4.0$ s). - Consumo RAM (< 250 MB).	**Técnicas:** - Telemetría automatizada en servidor AWS. - Pruebas de carga sintéticas. **Instrumentos:** - Scripts de benchmarking HTTP (k6 / wrk). - Registro de logs estructurados.
Sistematización P1: ¿Cuáles son los requerimientos técnicos y comerciales, y qué estructura relacional multimarca se requiere en Power Electrimk?	**Objetivo Específico 1 (O1):** Analizar los requerimientos operativos de cotización y la estructura de catálogos multimarca en Power Electrimk, fijando especificaciones de diseño.	**Hipótesis Específica 1 (H1):** La estructuración relacional normalizada en SQLite permite resolver consultas de inventario en $T_{\text{sql}} < 100$ ms con $100\,\%$ de integridad.	**Variable Dependiente 1 (VD1):** *Dimensión Estructura e Integridad de Catálogo:* Consistencia y celeridad de consulta de inventario técnico.	- Tiempo de ejecución SQL ($T_{\text{sql}} < 100$ ms). - Tasa de recuperación de SKU relevantes ($100\,\%$). - Integridad de atributos (código, precio, marca).	**Técnicas:** - Revisión bibliográfica de ingeniería. - Entrevista técnica a asesores comerciales. **Instrumentos:** - Guía de entrevista semiestructurada. - Matriz de extracción de atributos de catálogo.
Sistematización P2: ¿Cómo diseñar una arquitectura ligera en .NET 8 que integre WhatsApp, Gemini y SQLite preservando la memoria conversacional?	**Objetivo Específico 2 (O2):** Implementar un prototipo de microservicio en .NET 8 con persistencia SQLite WAL, orquestación Gemini y WhatsApp Cloud API.	**Hipótesis Específica 2 (H2):** La arquitectura asíncrona en .NET 8 procesa webhooks concurrentes sin bloqueos y con memoria de proceso < 250 MB.	**Variable Dependiente 2 (VD2):** *Dimensión Eficiencia de Recursos:* Huella computacional y concurrencia del servicio backend.	- Utilización de memoria RAM en .NET (< 250 MB). - Concurrencia de sesiones activas simultáneas. - Ocupación de CPU en servidor AWS ($< 30\,\%$).	**Técnicas:** - Inspección de procesos y perfilado de memoria. - Monitoreo de runtime en Kestrel / Linux. **Instrumentos:** - CLI dotnet-counters y dotnet-dump. - Métricas CloudWatch en AWS EC2.
Sistematización P3: ¿En qué medida la recuperación determinista mitiga la alucinación, mejora la exactitud y reduce la latencia P95 frente al modelo sin RAG?	**Objetivo Específico 3 (O3):** Evaluar el prototipo mediante pruebas experimentales comparativas cuantificando exactitud, tasa de alucinación y latencia P95.	**Hipótesis Específica 3 (H3):** El agente con recuperación local logra $H_{\text{rate}} = 0\,\%$, $Acc_{\text{cot}} \geq 95\,\%$ y $T_{\text{resp, P95}} < 4.0$ s con significancia ($p < 0{,}05$).	**Variable Dependiente 3 (VD3):** *Dimensión Exactitud Fáctica y Rendimiento:* Certeza técnica y celeridad de respuesta de cotización.	- Exactitud en cotización ($Acc_{\text{cot}} \geq 95\,\%$). - Tasa de alucinación fáctica ($H_{\text{rate}} = 0\,\%$). - Latencia en percentil P95 ($T_{\text{resp, P95}} < 4.0$ s). - Valor p de significancia ($p < 0{,}05$).	**Técnicas:** - Ensayo experimental controlado (control vs. experimental). - Prueba de hipótesis estadística (t-Student / Wilcoxon). **Instrumentos:** - Batería de $N = 50$ casos de prueba estructurados. - Matriz de cotejo de precios vs. catálogo base.

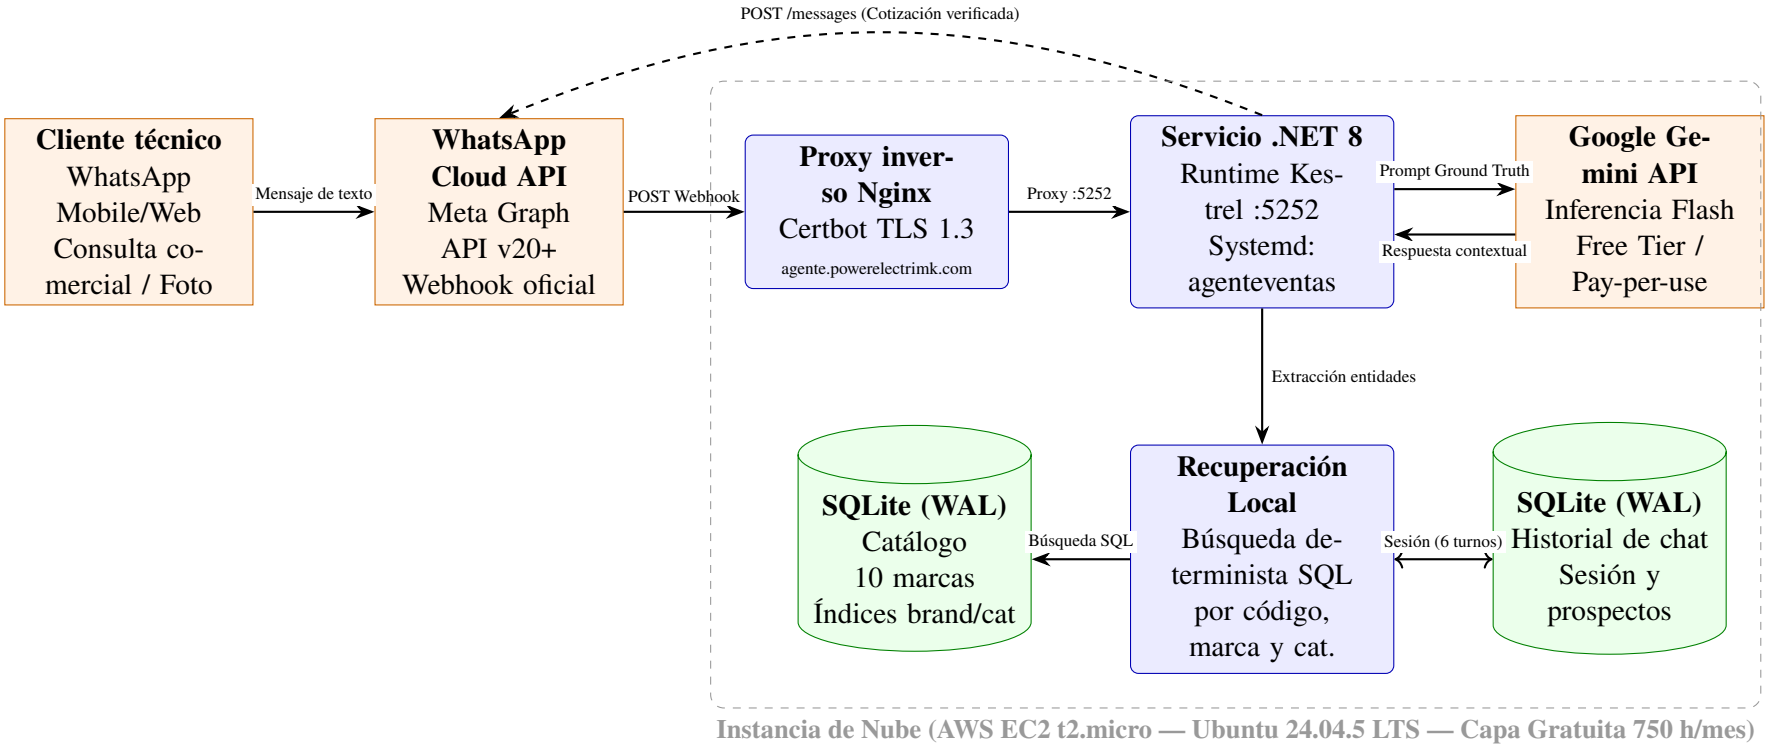
Nota. Matriz adaptada de la plantilla oficial de consistencia de la investigación UPS Sede Guayaquil (P69).

11.3. Anexo 3: Diagrama de arquitectura de software y flujo de procesamiento

En la Figura 4 se ilustra la arquitectura de componentes y el flujo secuencial de procesamiento de mensajes del agente conversacional, detallando la interacción entre los servicios externos de mensajería e inferencia y la infraestructura de cómputo local en la nube.

Figura 4

Arquitectura integral del agente inteligente para la atención comercial con recuperación local de catálogos



Nota. Diagrama arquitectónico del flujo de ejecución desacoplado entre el webhook de mensajería, el backend en .NET 8, el almacenamiento local embebido y el servicio de inferencia en la nube.

11.4. Anexo 4: Repositorio de código abierto y transparencia de datos

En estricto cumplimiento con el criterio de evaluación ABET IV.3 (Ética, Impacto y Reproducibilidad en Ingeniería), se formaliza el compromiso de acceso abierto a los artefactos de investigación:

1. **Repositorio de código fuente:** Todo el código fuente del microservicio backend, los scripts de migración y estructuración de catálogos y las herramientas de benchmarking automatizado serán gestionados y publicados en el repositorio institucional público de GitHub:

   https://github.com/vtotoy/agente-ventas-power

2. **Licenciamiento de software:** El software se distribuye bajo los términos de la licencia de código abierto **MIT License**, permitiendo la auditoría por pares, su reutilización académica y la transferencia tecnológica sin fines de lucro hacia otras micro y pequeñas empresas ecuatorianas.

3. **Gobernanza y anonimización de datos (LOPDP):** Los conjuntos de datos de prueba, trazas de telemetría y transcripciones experimentales publicadas en el repositorio se someterán a un protocolo riguroso de anonimización irreversible. Los números telefónicos y nombres de personas naturales son sustituidos por identificadores sintéticos disociados (*UUIDs*), garantizando el pleno acatamiento de la Ley Orgánica de Protección de Datos Personales del Ecuador.

4. **Guía de reproducibilidad computacional:** El repositorio incluye las directrices técnicas, el archivo `Dockerfile` de compilación multicapa y los procedimientos documentados paso a paso para desplegar el entorno de evaluación sobre cualquier distribución Linux con el runtime de .NET 8 y SQLite preinstalados.